

Mô hình nhận dạng ngôn ngữ ký hiệu liên tục nhẹ dựa trên keypoint sử dụng kiến trúc đa luồng và hợp nhất theo cơ chế cổng

Hoàng Đức Tân
Trường Công nghệ Thông tin và Truyền thông
Đại học Bách khoa Hà Nội
hoangductan733@gmail.com

Tháng 05, 2026

Tóm tắt nội dung

Nhận dạng ngôn ngữ ký hiệu liên tục (Continuous Sign Language Recognition – CSLR) là bài toán ánh xạ một đoạn video ngôn ngữ ký hiệu *chưa được phân đoạn* sang chuỗi gloss (dạng nhãn từ vựng biểu diễn ngữ nghĩa của mỗi sign) tương ứng. Trong toàn bộ pipeline chuyển đổi từ ngôn ngữ ký hiệu sang ngôn ngữ tự nhiên (Sign Language Translation – SLT) [?], CSLR đóng vai trò là bước trung gian then chốt: nó chuyển video ký hiệu thô thành biểu diễn ngữ nghĩa rời rạc ở cấp độ gloss, làm đầu vào cho các mô-đun dịch sang ngôn ngữ tự nhiên ở giai đoạn sau. Các phương pháp gần đây đã đạt được độ chính xác cao, nhưng hầu hết đều dựa trên video RGB cùng các mạng nơ-ron tích chập không-thời gian (spatio-temporal CNN) lớn, đòi hỏi nhiều ngày huấn luyện trên các hạ tầng lớn. Điều này hạn chế khả năng triển khai trên các thiết bị biên (edge devices) và gây khó khăn cho việc tái lập kết quả ở các phòng thí nghiệm có nguồn lực tính toán hạn chế. Trong nghiên cứu này, chúng tôi đề xuất một mô hình CSLR *cực nhẹ* hoạt động hoàn toàn trên các điểm chính (keypoint) của cơ thể, được tổ chức theo kiến trúc đa luồng (multi-stream) phân tách theo modality giải phẫu — gồm pose toàn thân, tay trái, tay phải, miệng và khuôn mặt — sau đó hợp nhất qua cơ chế cổng (gating) phụ thuộc thời gian. Trên bộ dữ liệu chuẩn RWTH-PHOENIX-Weather-2014T [?], mô hình đề xuất với khoảng 1,89M tham số đạt Word Error Rate (WER) 34,67% trên tập dev và 35,39% trên tập test, được huấn luyện *trọn vẹn trên một GPU NVIDIA GeForce MX450 2 GB VRAM trong khoảng 4 giờ*. Mô hình cũng được thẩm định trên RWTH-PHOENIX-Weather-2014 (bản gốc, không có bản dịch) với cùng kiến trúc không thay đổi, đạt WER 36,16% (dev) và 35,73% (test). Kết quả cho thấy chiến lược phân tách mô hình theo modality giải phẫu có thể mang lại hiệu suất CSLR đáng kể với một mô hình nhỏ hơn các hệ thống thông thường từ một đến hai bậc độ lớn, mở ra hướng đi thực tiễn cho việc nhận dạng ngôn ngữ ký hiệu trên các thiết bị biên.

Từ khóa: nhận dạng ngôn ngữ ký hiệu liên tục, keypoint, mô hình nhẹ, hợp nhất đa modality, mạng tích chập thời gian giãn nở, CTC, PHOENIX-2014T, PHOENIX-2014.

1 Mở đầu

Theo Tổ chức Y tế Thế giới, hơn 5% dân số toàn cầu — tương đương khoảng 466 triệu người — đang sống với khiếm thính ở mức độ ảnh hưởng tới giao tiếp [?]. Ngôn ngữ ký hiệu là phương tiện giao tiếp tự nhiên của cộng đồng người Điếc, song khoảng cách ngôn ngữ giữa cộng đồng Điếc và cộng đồng người nghe vẫn còn rất lớn do hầu hết người nghe không thông thạo ngôn ngữ ký hiệu. Việc xây dựng một hệ thống dịch ngôn ngữ ký hiệu tự động, hoạt động theo thời

gian thực và có khả năng triển khai trên thiết bị di động có thể mang giá trị xã hội, hỗ trợ giao tiếp hằng ngày, tạo điều kiện tiếp cận thông tin cho người Điếc.

Trong toàn bộ pipeline xử lý ngôn ngữ ký hiệu (Sign language processing - SLP), *nhận dạng ngôn ngữ ký hiệu liên tục* (Continuous Sign Language Recognition - CSLR) đóng vai trò trung tâm: đó là bước trung gian giữa video ngôn ngữ ký hiệu thô và bản dịch văn bản trong các kiến trúc dịch hai pha (Sign - gloss, gloss - text) [?]. Đầu vào của CSLR là một đoạn video chứa nhiều dấu hiệu (sign) nối tiếp, mỗi sign tương ứng với một đơn vị ngữ nghĩa của ngôn ngữ ký hiệu; đầu ra là một chuỗi gloss — các nhân từ vựng biểu diễn mỗi sign theo thứ tự xuất hiện trong video. Chúng tôi tin rằng việc cải thiện trong quy trình Sign - Gloss sẽ đóng vai trò chủ đạo trong việc hình thành lên các state of the art trong tương lai.

CSLR đã phát triển và cải tiến qua rất nhiều các phương pháp. Các phương pháp tiên tiến hiện nay có thể được phân thành ba nhóm chính. Nhóm thứ nhất, chiếm tỉ trọng lớn nhất, sử dụng trực tiếp video RGB làm đầu vào và kiến trúc học sâu hai pha: kết hợp mạng nơ-ron tích chập (Convolutional Neural Network - CNN) hai chiều để rút trích đặc trưng không gian theo từng khung hình với mạng tích chập một chiều theo thời gian (Temporal Convolutional Network - TCN) [?] hoặc mạng tích chập ba chiều (3D-CNN), sau đó nối tiếp một mạng hồi quy hai chiều dài-ngắn hạn (Bidirectional Long Short-Term Memory - BiLSTM) hoặc Transformer, và huấn luyện với hàm mất mát Connectionist Temporal Classification (CTC) [?] để học căn chỉnh ngầm giữa khung hình và gloss. Tiêu biểu cho hướng này gồm Sign Language Transformer (SLT) của Camgoz và cộng sự [?], Visual Alignment Constraint (VAC) của Min và cộng sự — phương pháp ép cả nhánh visual encoder và nhánh sequential encoder cùng dự đoán được chuỗi gloss để cải thiện chất lượng biểu diễn từng khung hình [?], Self-Mutual Knowledge Distillation (SMKD) — mở rộng VAC bằng cách chia sẻ trọng số bộ phân lớp giữa hai nhánh để đưa hai biểu diễn về cùng không gian ngữ nghĩa [?], và Correlation Network (CorrNet) — mạng học sâu khai thác tương quan vùng-theo-vùng giữa các khung hình [?]. Nhóm thứ hai khai thác keypoint do các bộ ước lượng pose như OpenPose [?] hoặc MediaPipe [?] trích xuất, sử dụng mạng tích chập đồ thị (Graph Convolutional Network - GCN) [?] hoặc các mạng tuần tự để xử lý chuỗi tọa độ; tiêu biểu là SignBERT [?], CoSign [?], và MSKA-SLR [?]. Nhóm thứ ba kết hợp đa modality (RGB cùng pose hoặc keypoint) thông qua các chiến lược chưng cất tri thức (knowledge distillation) hoặc hợp nhất (fusion) ở mức đặc trưng, điển hình là TwoStream-SLR [?] — thường đạt kết quả tốt nhất nhưng đánh đổi bằng kích thước mô hình rất lớn.

Mặc dù đạt độ chính xác cao, các phương pháp nêu trên đều bộc lộ những hạn chế làm cản trở việc ứng dụng thực tiễn. *Thứ nhất*, khối lượng tham số của các mô hình thường rất lớn: các backbone dựa trên ResNet, S3D, hoặc Video Swin thường có hàng chục đến hơn một trăm triệu tham số, khiến việc triển khai trực tiếp trên thiết bị di động, kính thông minh, hoặc thiết bị biên là không khả thi. *Thứ hai*, yêu cầu phần cứng huấn luyện rất cao: các báo cáo công bố hầu hết được huấn luyện trên cụm GPU cấp doanh nghiệp như NVIDIA V100 hoặc A100 với 16–80 GB bộ nhớ video trong nhiều ngày đến vài tuần, tạo rào cản về khả năng tái lập và nghiên cứu mở ở các phòng thí nghiệm có nguồn lực hạn chế. *Thứ ba*, các mô hình RGB toàn cảnh xử lý đồng thời thân, tay, miệng và mặt trên cùng một đặc trưng dùng chung, đánh mất khả năng tách bạch theo modality giải phẫu, trong khi ngôn ngữ ký hiệu vốn có tính đa kênh bản chất: tay có vai trò chủ đạo trong việc biểu diễn ngôn ngữ ký hiệu, các bộ phận khác như miệng, dáng, hướng khuôn mặt sẽ được xem như những yếu tố hỗ trợ. *Cuối cùng*, pixel RGB nhạy cảm với điều kiện ánh sáng, nền cảnh, và đặc điểm cá nhân của người ký hiệu, dẫn tới khoảng cách miền (domain gap) lớn khi triển khai trong môi trường thực tế.

Những hạn chế trên đặt ra câu hỏi nghiên cứu trung tâm của công trình này: *liệu có thể xây dựng một mô hình CSLR đủ chính xác để có ý nghĩa thực tiễn, đồng thời đủ nhẹ để có thể huấn luyện và triển khai trên phần cứng phổ thông hay không?*

Để trả lời câu hỏi trên, chúng tôi đề xuất chuyển sang biểu diễn keypoint chuẩn hóa thay cho pixel thô, đồng thời tách rời mô hình theo modality giải phẫu. Cụ thể, mô hình của chúng tôi gồm năm bộ mã hóa độc lập tương ứng với pose toàn thân, tay trái, tay phải, miệng và khuôn

mặt; mỗi bộ mã hóa được thiết kế nhẹ với chuỗi xử lý chiếu tuyến tính (Linear projection) → mạng tích chập thời gian giãn nở (Dilated TCN — kiến trúc ban đầu được đề xuất trong WaveNet [?]) và được Bai và cộng sự [?] chứng minh là một thay thế hiệu quả cho LSTM trong mô hình hóa chuỗi nhờ vùng tiếp nhận theo cấp số nhân và tính song song hóa cao) → mạng hồi quy hai chiều dùng nút có cổng (Bidirectional Gated Recurrent Unit – BiGRU) [?], phù hợp với số chiều đầu vào nhỏ của keypoint. Đầu ra của năm luồng được hợp nhất qua cơ chế cổng *phụ thuộc thời gian* (per-frame gated fusion): tại mỗi khung hình, một perceptron đa lớp nhẹ (Multi-Layer Perceptron – MLP) sinh ra vector trọng số đóng góp $\alpha_t \in \mathbb{R}^5$, cho phép mô hình tự học mức độ đóng góp của từng kênh tại từng thời điểm tùy theo nội dung sign đang diễn ra. Ngoài hàm mất mát CTC chính, chúng tôi bổ sung các nhánh giám sát phụ trợ *chia sẻ trọng số phân lớp với nhánh chính*, lấy cảm hứng từ VAC [?] và SMKD [?], gồm một nhánh visual auxiliary trên đặc trưng hợp nhất và ba nhánh per-stream auxiliary trên các luồng tay trái, tay phải, và miệng (do 3 nhánh này được xem xét là 3 thành phần có giá trị thay đổi lớn nhất theo các khung hình). Việc dùng chung bộ phân lớp giữa các nhánh ép từng bộ mã hóa học được biểu diễn nằm trên cùng không gian ngữ nghĩa, hoạt động như một dạng giám sát đa cấp (deep supervision) giúp mô hình nhỏ tránh underfitting.

Đóng góp chính của nghiên cứu này có thể tóm tắt ở ba điểm:

1. Đề xuất một kiến trúc CSLR cực nhẹ ($\sim 1.89\text{M}$ tham số) hoàn toàn dựa trên keypoint, được phân tách theo năm modality giải phẫu (pose, tay trái, tay phải, miệng, khuôn mặt) và hợp nhất qua cơ chế cổng phụ thuộc thời gian trong không gian keypoint thuần túy.
2. Thiết kế chiến lược giám sát đa cấp gồm nhánh visual auxiliary và các nhánh per-stream auxiliary chia sẻ trọng số phân lớp với nhánh chính, giúp tăng cường giám sát từng modality riêng biệt mà vẫn giữ được tổng số tham số nhỏ.
3. Chứng minh trên bộ dữ liệu chuẩn RWTH-PHOENIX-Weather-2014T [?] rằng mô hình đề xuất có thể được huấn luyện *trọn vẹn trên một GPU 2 GB VRAM trong khoảng 4 giờ*, đạt WER 34,67% trên tập dev và 35,39% trên tập test — một mức chính xác có ý nghĩa với tài nguyên tính toán giới hạn.
4. Tạo tiền đề cho việc triển khai các mô hình nhẹ trên các thiết bị biên trong tương lai.

Phần còn lại của bài báo được tổ chức như sau. Mục 2 trình bày các nghiên cứu liên quan. Mục 3 mô tả chi tiết phương pháp đề xuất. Mục ?? trình bày phương pháp thực nghiệm, kết quả và phân tích. Cuối cùng, Mục ?? kết luận và hướng phát triển.

2 Các nghiên cứu liên quan

2.1 Nhận dạng ngôn ngữ ký hiệu liên tục dựa trên video RGB

Camgoz và cộng sự [?] giới thiệu bộ dữ liệu chuẩn PHOENIX-2014T cùng phương pháp Sign Language Transformer, đặt nền móng cho nhánh nghiên cứu CSLR trên video RGB và sử dụng đồng thời CTC để học căn chỉnh ngầm. Một loạt các công trình tiếp theo tập trung cải tiến phần rút trích đặc trưng và phần học chuỗi. VAC (Visual Alignment Constraint) [?] đưa ra ý tưởng ép phần visual encoder và phần sequential encoder cùng dự đoán được chuỗi gloss, qua đó cải thiện chất lượng biểu diễn từng khung hình. SMKD [?] mở rộng VAC bằng cách chia sẻ trọng số bộ phân lớp giữa hai nhánh, làm cho hai biểu diễn nằm cùng không gian ngữ nghĩa. CorrNet [?] đưa thêm khối Body Correlation và Temporal Correlation để mô hình hóa quan hệ vùng–theo–vùng qua các khung hình. TwoStream–SLR [?] hợp nhất nhánh RGB và nhánh keypoint thông qua distillation chéo, đạt kết quả thuộc nhóm dẫn đầu trên PHOENIX-2014T nhưng cũng kéo theo chi phí tính toán đáng kể.

Điểm chung của các phương pháp này là dựa trên backbone 2D-CNN/3D-CNN cơ ResNet-18, S3D, hoặc Video Swin, với số tham số dao động từ hàng chục đến hơn một trăm triệu, và yêu cầu cụm GPU dung lượng lớn để huấn luyện.

2.2 Nhận dạng dựa trên keypoint và mạng đồ thị

Nhằm giảm phụ thuộc vào pixel RGB, một số công trình chuyển sang biểu diễn keypoint do OpenPose [?] hoặc MediaPipe [?] cung cấp. ST-GCN [?], ban đầu được đề xuất cho nhận dạng hành động, được nhiều nhóm áp dụng cho nhận dạng ngôn ngữ ký hiệu đẳng cấp (Isolated SLR) và mở rộng cho CSLR. SignBERT [?] đề xuất pretraining khối Transformer trên dữ liệu keypoint tay quy mô lớn, sau đó fine-tune cho các tác vụ hạ nguồn. Gần đây, CoSign [?] đề xuất sử dụng GCN khai thác các tín hiệu *đồng-xuất hiện* (co-occurrence) giữa các bộ phận cơ thể trong skeleton, đạt WER cạnh tranh với các phương pháp video RGB trên PHOENIX-2014T trong khi giảm đáng kể chi phí tính toán huấn luyện. MSKA-SLR [?] tổ chức skeleton thành bốn luồng và áp dụng cơ chế attention nhiều tầng để học biểu diễn theo modality. Mặc dù tiết kiệm tham số hơn nhánh RGB, các phương pháp keypoint hiện tại thường vẫn dùng Transformer hoặc GCN khá nặng và cần GPU dung lượng lớn để huấn luyện, và phần lớn chưa khai thác triệt để tính chất phân tách theo modality giải phẫu của ngôn ngữ ký hiệu trong một mô hình thực sự nhẹ.

2.3 Hợp nhất đa modality theo cơ chế cổng

Cơ chế cổng (gating) cho hợp nhất đa modality đã được nghiên cứu rộng rãi trong các bài toán nhận dạng cảm xúc đa phương thức và VQA. Trong CSLR, TwoStream-SLR [?] kết hợp hai nhánh RGB và pose ở nhiều mức bằng các khối cross-attention. Ý tưởng chung là cho phép mô hình tự học mức độ đóng góp của từng modality tại từng vị trí thời gian thay vì hợp nhất bằng tổng/nối cố định. Mô hình của chúng tôi mở rộng ý tưởng này sang *năm* luồng giải phẫu (thay vì hai), trên không gian keypoint thuần túy, và sử dụng cổng nhẹ dạng MLP trên đặc trưng nối, qua đó tránh được chi phí tính toán bình phương theo độ dài chuỗi của cross-attention.

2.4 Mạng tích chập thời gian giãn nở (Dilated TCN)

Dilated TCN, khởi nguồn từ WaveNet [?], đã được chứng minh là một thay thế hiệu quả cho LSTM trong nhiều tác vụ chuỗi nhờ vùng tiếp nhận theo cấp số nhân và tính song song hóa cao. Bai và cộng sự [?] cho thấy TCN ngang ngửa hoặc vượt LSTM trên hàng loạt benchmark. Trong CSLR, TCN thường được dùng làm khối thời gian trung gian sau backbone không gian. Chúng tôi áp dụng phiên bản depthwise-separable Dilated TCN với dilation [1, 2, 4, 8] để đạt vùng tiếp nhận ~ 31 khung hình ($\approx 1,2$ giây ở 25 fps) trong khi vẫn giữ số tham số nhỏ (khoảng $3\times$ nhẹ hơn Conv1d đầy đủ tương đương ở cùng số kênh $C=128$, kernel 3).

2.5 Bài học rút ra


Tổng kết lại, các nghiên cứu hiện có cho ba bài học định hướng cho thiết kế của chúng tôi: (i) keypoint là biểu diễn đủ giàu để học CSLR nếu được mô hình hóa thời gian đúng cách, (ii) các nhánh giám sát phụ trợ kiểu VAC/SMKD cải thiện chất lượng biểu diễn ở chi phí gần như bằng không, và (iii) hợp nhất modality theo cơ chế cổng linh hoạt hơn hợp nhất tĩnh và phù hợp với tính đa kênh của ngôn ngữ ký hiệu.

3 Phương pháp đề xuất

3.1 Tổng quan kiến trúc

Kiến trúc tổng thể của mô hình đề xuất được minh họa ở Hình 1. Hệ thống nhận vào tensor keypoint $X \in \mathbb{R}^{B \times T \times 77 \times 3}$, trong đó B là kích thước batch, T là độ dài chuỗi, 77 là số keypoint chuẩn hóa trên mỗi khung hình, và 3 là (x, y, c) với c là độ tin cậy của bộ ước lượng pose. Pipeline gồm bốn giai đoạn chính:

1. **Tách năm luồng:** chuỗi keypoint được chia theo các slice cố định thành pose (9 điểm), tay trái (21), tay phải (21), miệng (12) và khuôn mặt (14).
2. **Bộ mã hóa từng luồng:** mỗi luồng được đưa qua một mạng Linear $\rightarrow$ LayerNorm $\rightarrow$ Dilated TCN $\rightarrow$ BiGRU độc lập, cho ra đặc trưng $h^{(s)} \in \mathbb{R}^{B \times T \times 128}$.
3. **Hợp nhất theo cổng (Gated Fusion):** năm vector đặc trưng được kết hợp qua trọng số α_t phụ thuộc thời gian, sinh ra đặc trưng hợp nhất $f \in \mathbb{R}^{B \times T \times 128}$.
4. **Tinh chỉnh thời gian và đầu CTC:** một BiGRU hai lớp tinh chỉnh ngữ cảnh toàn câu, sau đó lớp tuyến tính chiếu lên không gian 1124 lớp và áp dụng log-softmax để dùng cho CTC loss.



Hình 1: Sơ đồ tổng quan của mô hình đề xuất. Năm luồng giải phẫu được mã hóa độc lập, hợp nhất qua cổng phụ thuộc thời gian, tinh chỉnh thời gian và phân lớp bằng CTC.

3.2 Tiền xử lý và biểu diễn keypoint

Mỗi khung hình của video gốc được trích xuất 77 keypoint chuẩn hóa, sắp xếp theo thứ tự cố định pose $\rightarrow$ tay trái $\rightarrow$ tay phải $\rightarrow$ miệng $\rightarrow$ khuôn mặt (Bảng ??). Việc đặt thứ tự cố định cho phép tách năm luồng chỉ bằng các slice tensor, loại bỏ chi phí gather động.

Đặc trưng vận tốc. Bên cạnh tọa độ (x, y, c) thô, chúng tôi bổ sung đặc trưng vận tốc $(\Delta x, \Delta y)$ tính bằng sai phân hữu hạn giữa hai khung hình liên tiếp.

Bảng 1: Phân bố 77 keypoint theo năm luồng giải phẫu.

Luồng	Slice	Số điểm	Vai trò ngữ nghĩa
Pose (thân)	[0 : 9]	9	Ngữ cảnh không gian, vai/đầu
Tay trái	[9 : 30]	21	Modality chính #1
Tay phải	[30 : 51]	21	Modality chính #2
Miệng	[51 : 63]	12	Mouthing, phân biệt cử chỉ đồng dạng
Khuôn mặt	[63 : 77]	14	Biểu cảm/ngữ pháp
Tổng		77	

Tăng cường dữ liệu. Bốn phép biến đổi xác suất được áp dụng trong huấn luyện: lấy mẫu lại theo thời gian (xác suất 0,5, tỉ lệ $\in [0,7; 1,3]$), nhiễu Gauss trên (x, y) với $\sigma = 0,005$ (xác suất 0,5), xoay 2D ngẫu nhiên trong $[-0,15; 0,15]$ radian (xác suất 0,3), và keypoint dropout zero-out ngẫu nhiên một số điểm với tỉ lệ $p_{\text{drop}} = 0,05$ trên mỗi keypoint (xác suất kích hoạt là 0,2). Các phép biến đổi này được thêm vào để làm phong phú data và làm cho mô hình trở nên robust hơn trước nhiễu.

3.3 Bộ mã hóa từng luồng

Mỗi luồng đi qua một module *StreamEncoder* gồm ba khối nối tiếp.

(1) Chiều tuyến tính. Đặc trưng $[B, T, J, 5]$ của luồng (với J là số keypoint của luồng) được làm phẳng theo chiều khớp thành $[B, T, 5 * J]$ rồi chiếu tuyến tính lên không gian embedding $d = 128$ chiều:

$$z_t = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{x}_t W + b))), \quad (1)$$

trong đó $\mathbf{x}_t \in \mathbb{R}^{5J}$ là vector đặc trưng đầu vào của luồng tại khung hình t , thu được bằng cách làm phẳng J keypoint của luồng đó với 5 kênh mỗi keypoint $(x, y, c, \Delta x, \Delta y)$ (tọa độ chuẩn hóa, độ tin cậy của bộ ước lượng pose, và vận tốc theo hai trục); $W \in \mathbb{R}^{128 \times 5J}$ là ma trận trọng số học được của phép chiếu tuyến tính từ không gian đầu vào $5J$ chiều lên không gian embedding 128 chiều; và $b \in \mathbb{R}^{128}$ là vector bias học được. Đầu ra $W\mathbf{x}_t + b$ tiếp đó được đi qua LayerNorm để chuẩn hóa thống kê, hàm kích hoạt GELU và Dropout, cho ra biểu diễn $z_t \in \mathbb{R}^{128}$ của luồng tại khung hình t .


(2) Mạng tích chập thời gian giãn nở. Mục tiêu là học các mẫu chuyển động ngắn-đến-trung trên trục thời gian. Khối TCN gồm bốn tầng depthwise-separable Conv1d với dilation $\{1, 2, 4, 8\}$, kernel size 3, BatchNorm và kích hoạt GELU:

$$h^{\text{tcn}} = \text{GELU}(\text{TCN}(z) + z W_{\text{skip}}). \quad (2)$$

trong đó $z \in \mathbb{R}^{B \times T \times 128}$ là đầu ra của bước chiếu tuyến tính ở phần (1); $\text{TCN}(\cdot)$ ký hiệu phép biến đổi tổng hợp của bốn tầng depthwise-separable Conv1d giãn nở trên; và W_{skip} là ma trận trọng số học được của một lớp tích chập điểm (1×1 Conv) trên nhánh tắt (skip connection). W_{skip} có vai trò vừa khớp số kênh giữa đầu vào và đầu ra của khối TCN khi cần, vừa cung cấp đường dẫn gradient ngắn giúp ổn định quá trình huấn luyện và tránh hiện tượng tiêu biến gradient ở các tầng sâu.

(3) BiGRU. Sau TCN, chuỗi đặc trưng được đưa qua một lớp GRU hai chiều với 64 đơn vị mỗi chiều, cho ra đầu ra 128 chiều. GRU nhẹ hơn LSTM và phù hợp với chuỗi không quá dài của các video PHOENIX ($T \leq 300$ khung hình).

Đầu ra của mỗi luồng s được ký hiệu $h^{(s)} \in \mathbb{R}^{B \times T \times 128}$.



Hình 2: Kiến trúc Dilated TCN theo phong cách WaveNet dùng trong đồ án. (a) Ngăn xếp bốn tầng tích chập nhân quả giãn nở với dilation $d \in \{1, 2, 4, 8\}$ (kernel 3): mỗi nút lấy đầu vào từ các bước thời gian $t, t-d, t-2d$ ở tầng dưới (mũi tên cam ứng với bước nhảy d , mũi tên xanh ứng với $2d$), cho vùng tiếp nhận 31 khung hình ($\approx 1,2$ s ở 25 fps). (b) Chi tiết một khối residual: hai lớp Depthwise-Separable Convolution giãn nở, mỗi lớp kèm Batch Normalization và kích hoạt phi tuyến, cùng kết nối tắt qua tích chập 1×1 và phép cộng $\mathbf{h}_t = \sigma(\text{BN}(\text{DWConv}_d(\mathbf{x}_t))) + \mathbf{x}_t$.

3.4 Hợp nhất theo công phụ thuộc thời gian

Năm vector đặc trưng được stack thành tensor $H \in \mathbb{R}^{B \times T \times 5 \times 128}$. Tại mỗi khung hình t , một MLP nhẹ tính trọng số đóng góp $\alpha_t \in \mathbb{R}^5$:

$$\tilde{\alpha}_t = W_2 \text{GELU}(W_1 \cdot \text{concat}(H_t)), \quad (3)$$

$$\alpha_t = \text{softmax}(\tilde{\alpha}_t), \quad (4)$$

trong đó $\text{concat}(H_t) \in \mathbb{R}^{640}$ là vector thu được bằng cách nối tiếp 5 vector đặc trưng 128 chiều của 5 luồng tại khung hình t (do đó có tổng số chiều $5 \times 128 = 640$); $W_1 \in \mathbb{R}^{320 \times 640}$ là ma trận trọng số học được của tầng thứ nhất của một MLP hai tầng, chiều vector nối từ không gian 640 chiều xuống không gian ẩn 320 chiều; $W_2 \in \mathbb{R}^{5 \times 320}$ là ma trận trọng số học được của tầng thứ hai, chiều từ 320 chiều xuống 5 chiều logits, mỗi chiều tương ứng với một luồng giải phẫu. Hàm softmax sau đó chuẩn hóa 5 logits thô $\tilde{\alpha}_t$ thành phân phối trọng số đóng góp $\alpha_t \in \mathbb{R}^5$ thỏa $\sum_{s=1}^5 \alpha_{t,s} = 1$ và $\alpha_{t,s} \geq 0$. Đặc trưng hợp nhất sau đó là tổng có trọng số:

$$f_t = \text{LN} \left(\sum_{s=1}^5 \alpha_{t,s} \cdot h_t^{(s)} \right). \quad (5)$$

Việc tính α_t theo từng khung hình cho phép mô hình tăng đóng góp của `left/right_hand` ở các khung có cử chỉ tay rõ rệt, và tăng đóng góp của `mouth/face` khi mouthing hoặc biểu cảm ngữ pháp xuất hiện.

3.5 Tinh chỉnh thời gian và đầu CTC

Đặc trưng hợp nhất f được tinh chỉnh bằng một BiGRU hai lớp với hidden size 128 (đầu ra 256 chiều), nhằm học các phụ thuộc dài hơn vùng tiếp nhận của TCN, ví dụ thứ tự trước-sau giữa các sign và biên giới gloss. Lớp tuyến tính cuối cùng chiếu đặc trưng tinh chỉnh lên số lớp $C = 1124$ (gồm token blank và bộ từ vựng gloss của bộ dữ liệu Phoenix-2014T), kết quả được đưa qua log-softmax để tạo $\log p_\theta(y_t | X) \in \mathbb{R}^{B \times T \times C}$.

3.6 Hàm mất mát

CTC chính. Vì không có căn chỉnh sẵn giữa khung hình và gloss, chúng tôi sử dụng Connectionist Temporal Classification (CTC) [?]:

$$\mathcal{L}_{\text{ctc}} = -\log \sum_{\pi \in \mathcal{B}^{-1}(y)} \prod_{t=1}^T p_\theta(\pi_t | X), \quad (6)$$

trong đó $\mathcal{B}$ là phép thu gọn (collapse repeats + remove blank) và y là chuỗi gloss tham chiếu.

Giám sát phụ trợ. Lấy cảm hứng từ VAC [?] và SMKD [?], chúng tôi bổ sung các nhánh giám sát phụ trợ *chia sẻ trọng số phân lớp* với nhánh chính. Cụ thể:

- **Visual aux:** đặc trưng sau hợp nhất f được chiếu qua một module Linear $\rightarrow$ LN về cùng chiều 256 rồi đưa thẳng vào đầu CTC dùng chung. Hàm mất mát tương ứng $\mathcal{L}_{\text{visual}}$ ép biểu diễn thị giác và biểu diễn chuỗi nằm trên cùng không gian ngữ nghĩa.
- **Per-stream aux:** đặc trưng từ ba luồng quan trọng nhất (tay trái, tay phải, miệng) được chiếu lên 256 chiều và đưa vào đầu CTC dùng chung, sinh ra ba hàm mất mát phụ $\mathcal{L}_{\text{LH}}, \mathcal{L}_{\text{RH}}, \mathcal{L}_{\text{mouth}}$. Việc dùng chung classifier ép từng bộ mã hóa tự học được phân phối gloss trên từng modality, hoạt động như một dạng deep supervision.

Hàm mất mát tổng:

$$\mathcal{L} = \mathcal{L}_{\text{ctc}} + \lambda_v \mathcal{L}_{\text{visual}} + \lambda_{\text{LH}} \mathcal{L}_{\text{LH}} + \lambda_{\text{RH}} \mathcal{L}_{\text{RH}} + \lambda_m \mathcal{L}_{\text{mouth}}, \quad (7)$$

với trọng số $\lambda_v = 1,0$, $\lambda_{\text{LH}} = \lambda_{\text{RH}} = 0,3$, $\lambda_m = 0,2$. Lựa chọn λ ưu tiên tay so với miệng phản ánh thứ tự đóng góp ngữ nghĩa của các modality.

3.7 Giải mã suy luận

Tại pha suy luận, chúng tôi dùng giải mã CTC tham lam: argmax theo từng khung hình, sau đó thu gọn các token liên tiếp trùng nhau và loại bỏ token blank. Phương pháp này không cần mô hình ngôn ngữ ngoại vi và có độ phức tạp $O(T)$, phù hợp với triển khai thời gian thực.

4 Thực nghiệm

4.1 Bộ dữ liệu

Chúng tôi đánh giá mô hình trên **RWTH-PHOENIX-Weather-2014T** [?], bộ dữ liệu chuẩn cho CSLR Đức. Bộ dữ liệu gồm các bản tin dự báo thời tiết được ký bằng Tiếng ký hiệu Đức (DGS) bởi 9 người ký hiệu. Sau khi tiền xử lý keypoint, ba tập theo phân chia chính thức được sử dụng trong thực nghiệm gồm: tập huấn luyện 7094 mẫu, tập phát triển (dev) 519 mẫu, và tập kiểm thử (test) 642 mẫu.

Mỗi mẫu trong bộ dữ liệu đã được tiền xử lý thành tensor keypoint kích thước $[T, 77, 3]$, với T thay đổi theo độ dài đoạn ký hiệu. Theo thống kê trực tiếp trên dữ liệu được dùng, độ dài

trung bình của các chuỗi train/dev/test lần lượt là 116,6, 107,5 và 100,7 khung hình; cực đại lên tới 475 khung hình trên tập huấn luyện và ≤ 272 khung hình trên dev/test. Việc dùng keypoint cho phép loại bỏ ảnh hưởng của ánh sáng, nền cảnh, và đặc điểm cá nhân ở mức pixel.

4.2 Độ đo đánh giá

Theo chuẩn của lĩnh vực, chúng tôi sử dụng **Word Error Rate (WER)** trên chuỗi gloss, định nghĩa qua khoảng cách Levenshtein:

$$\text{WER} = \frac{S + D + I}{N}, \quad (8)$$

trong đó S, D, I lần lượt là số thay thế, xóa, chèn cần thực hiện để biến chuỗi dự đoán thành chuỗi tham chiếu, và N là độ dài chuỗi tham chiếu. WER càng thấp càng tốt.

Ngoài WER, chúng tôi báo cáo các chỉ số phụ phục vụ so sánh: số tham số, bộ nhớ VRAM tối đa khi huấn luyện, tổng thời gian huấn luyện, và độ trễ suy luận trên một chuỗi 200 khung hình.

4.3 Thiết lập huấn luyện

Toàn bộ mô hình được cài đặt bằng PyTorch 2 và huấn luyện trên một GPU NVIDIA GeForce MX450 có 2 GB VRAM. Cấu hình huấn luyện chi tiết được tóm tắt ở Bảng ??.

Bảng 2: Siêu tham số huấn luyện và phần cứng.

Hạng mục	Giá trị
Optimizer	AdamW
Base learning rate	1×10^{-3}
Weight decay	1×10^{-4}
Scheduler	OneCycleLR, cosine, 10% warmup
Gradient clipping	max_norm = 5,0
Batch size	16
Số epoch (cấu hình)	200 (lưu best theo dev WER)
Dropout	0,3
Embedding dim	128
TCN channels/kernel	128 / 3
TCN dilations	{1, 2, 4, 8}, vùng tiếp nhận 31 khung
GRU hidden (encoder)	64 (bi $\Rightarrow$ 128)
GRU hidden (refine)	128, 2 lớp (bi $\Rightarrow$ 256)
Trọng số aux	$\lambda_v = 1,0$; $\lambda_{LH/RH} = 0,3$; $\lambda_m = 0,2$
Tổng tham số học được	1 894 377 ($\approx 1,89\text{M}$)
GPU	NVIDIA GeForce MX450, 2 GB VRAM
Thời gian huấn luyện	~ 4 giờ
Framework	PyTorch 2.5.1 + CUDA 12.1

4.4 Kết quả chính

Mô hình đạt được **WER 34,67% trên tập dev** và **WER 35,39% trên tập test** của PHOENIX-2014T (Bảng ??). Đây là kết quả không sử dụng pretraining trên bất kỳ bộ dữ liệu ngoài nào và không sử dụng beam search hay mô hình ngôn ngữ. Checkpoint tốt nhất được chọn theo dev WER ở epoch 153.

Bảng 3: Kết quả chính của mô hình đề xuất trên PHOENIX-2014T. Tất cả kết quả không dùng pretraining ngoài và sử dụng giải mã greedy CTC, checkpoint chọn theo dev WER (epoch 153/200).

Cấu hình	#Tham số	Dev WER (%)	Test WER (%)
Mô hình đề xuất (đầy đủ)	1,89M	34,67	35,39

4.5 So sánh với các phương pháp khác

Bảng ?? so sánh mô hình đề xuất với một số phương pháp CSLR đại diện trên cùng bộ PHOENIX-2014T. Cần lưu ý rằng các phương pháp tham chiếu *không trực tiếp tương đương* về điều kiện thử nghiệm: chúng được huấn luyện trên cụm GPU dung lượng lớn, sử dụng video RGB và backbone CNN nặng, và phần lớn dùng beam search có mô hình ngôn ngữ ở pha giải mã. Mục tiêu của bảng vì vậy không phải là tuyên bố vượt trội về WER, mà là làm rõ *vùng đánh đổi (trade-off space)* mà mô hình của chúng tôi chiếm giữ: WER có thể cao hơn, nhưng đổi lại là quy mô tham số nhỏ hơn từ một đến hai bậc và yêu cầu phần cứng huấn luyện thấp hơn đáng kể.

Bảng 4: So sánh với các phương pháp CSLR đại diện trên PHOENIX-2014T (Sign2Gloss). Các giá trị WER được trích từ Bảng 1 của Wang *et al.* [?] cũng như báo cáo gốc tương ứng. Các giá trị số tham số có ghi chú (*dự đoán*) là ước lượng dựa trên mô tả kiến trúc trong báo cáo gốc, không phải con số do tác giả công bố trực tiếp. Các phương pháp nhánh trên dùng video RGB; nhánh dưới sử dụng *chỉ keypoint* — điều kiện công bằng hơn so với mô hình của chúng tôi.

Phương pháp	Modality	#Params	GPU train	Dev WER (%)	Test WER (%)
<i>Nhóm video RGB (dùng backbone CNN nặng):</i>					
SignBT [?]	RGB	~30M (dự đoán)	GPU server	22,7	23,9
STMC [?]	RGB	~30M (dự đoán)	GPU server	19,6	21,0
C2SLR [?]	RGB	~25M (dự đoán)	GPU server	20,2	20,4
SMKD [?]	RGB	~31.6M	GPU server	20,8	22,4
CorrNet [?]	RGB	~30M (dự đoán)	GPU server	18,9	20,5
TwoStream-SLR [?]	RGB + pose	~100M (dự đoán)	cụm GPU 32 GB+	17,7	19,3
SignBERT+ [?]	RGB	~110M (dự đoán)	GPU server	18,8	19,9
<i>Nhóm keypoint-only (so sánh trực tiếp với chúng tôi):</i>					
SignBERT+ (keypoint) [?]	Pose	~110M (dự đoán)	GPU server	32,9	33,6
TwoStream-SLR (keypoint) [?]	Pose	~50M (dự đoán)	GPU server	27,1	27,2
CoSign [?]	Skeleton (GCN)	~28.2M	GPU server	19,5	20,1
MSKA-SLR [?]	Pose (4 luồng)	—	RTX 3090 24 GB	20,1	20,5
Mô hình của chúng tôi	Keypoint (77)	1,89M	MX450 2 GB	34,67	35,39

Ghi chú về ước lượng tham số (dự đoán): VAC, SMKD và CorrNet đều dùng backbone ResNet-18 (~11M) cộng với khối 1D-TCN và BiLSTM (~10-20M tùy hidden size); con số ~24-30M là ước lượng dựa trên mô tả tương ứng. TwoStream-SLR hợp nhất hai nhánh S3D + pose nên ước lượng tổng quy mô lớn hơn. SignBERT+ ở quy mô BERT-base có khoảng 110M tham số. STMC, SignBT, C2SLR đều dùng backbone ResNet/VGG nên cỡ tham số tương đương VAC/SMKD. CoSign dùng một loạt khối GCN trên skeleton nên ước lượng tham số nhẹ hơn (vài triệu đến ~28M). **Các con số này là ước lượng kiến trúc và cần đối chiếu với mã nguồn/báo cáo gốc trước khi trích dẫn chính thức.**

Bốn điểm nổi bật cần nhấn mạnh từ so sánh trên:

- So sánh trong cùng họ keypoint-only.** Trong nhóm keypoint-only, các phương pháp dẫn đầu là CoSign (19,5/20,1%) [?] và MSKA-SLR (20,1/20,5%) [?], theo sau là TwoStream-SLR phiên bản keypoint (27,1/27,2%) và SignBERT+ phiên bản keypoint (32,9/33,6%). Mô hình của chúng tôi đạt 34,67/35,39%, gần ngang với SignBERT+ keypoint, kém CoSign/MSKA-SLR khoảng 15 điểm phần trăm trên dev và test. Tuy nhiên, MSKA-SLR được huấn luyện trên RTX 3090 24 GB và sử dụng kiến trúc 4 luồng với 8 attention block mỗi luồng (mỗi

block 6 head) [?], còn CoSign dùng nhiều khối GCN sâu trên skeleton; cả hai đều cần GPU tính toán cao hơn nhiều so với cấu hình của chúng tôi.

2. **Quy mô tham số.** Mô hình của chúng tôi chỉ 1,89 triệu tham số, nhỏ hơn các backbone ResNet-18 thường gặp trong nhánh RGB (~11M chỉ riêng backbone, dự đoán) khoảng 6 lần và nhỏ hơn các mô hình hai luồng RGB+pose như TwoStream-SLR.
3. **Tài nguyên huấn luyện.** Hầu hết các phương pháp tham chiếu được công bố với cấu hình huấn luyện gồm một hoặc nhiều GPU cấp doanh nghiệp (V100/A100/3090, 16–80 GB VRAM) trong nhiều ngày. Mô hình của chúng tôi được huấn luyện trọn vẹn trên *một GPU duy nhất NVIDIA MX450 2 GB VRAM trong ~4 giờ* trên toàn bộ 7 094 mẫu của PHOENIX-2014T. Đây là yếu tố thực tiễn quan trọng cho phép tái lập kết quả ở các môi trường hạn chế tài nguyên.
4. **Modality và pipeline.** Trong khi đa số phương pháp dẫn đầu phải xây dựng pipeline RGB phức tạp, mô hình của chúng tôi chỉ làm việc trên keypoint chuẩn hóa. Điều này giảm đáng kể nhạy cảm với nền cảnh, ánh sáng và đặc điểm cá nhân của người ký hiệu, đồng thời mở khả năng kết hợp trực tiếp với các bộ ước lượng pose chạy trên thiết bị di động như MediaPipe.

Khoảng cách WER giữa mô hình của chúng tôi và MSKA-SLR (~14–15 điểm WER) phản ánh đúng đánh đổi đã chọn: chúng tôi đã giảm đáng kể về dung lượng mô hình và phần cứng để hướng đến triển khai biên, trong khi MSKA-SLR ưu tiên độ chính xác trên GPU dung lượng lớn. So với SignBERT+ phiên bản keypoint-only (32,9/33,6%), mô hình của chúng tôi có WER cao hơn ~1,8 điểm trên cả dev và test, nhưng đổi lại nhỏ hơn rất nhiều về tham số và không cần pretraining thủ công quy mô lớn như SignBERT+.

4.6 Đánh giá trên PHOENIX-2014

Để kiểm tra khả năng tổng quát hóa, chúng tôi tiến hành tiền xử lý và huấn luyện thêm trên bộ RWTH-PHOENIX-Weather-2014 (bản gốc, không có bản dịch, ký hiệu **PHOENIX-2014**). Khác với PHOENIX-2014T, bộ dữ liệu này chứa 5 672 mẫu huấn luyện, 540 mẫu dev và 629 mẫu test, từ điển gloss gồm 1 138 token. Kiến trúc mô hình và toàn bộ siêu tham số giữ nguyên hoàn toàn; chỉ đường dẫn dữ liệu và từ điển được cập nhật.

Checkpoint tốt nhất đạt được ở epoch 172: **WER 36,16% trên tập dev** và **WER 35,73% trên tập test**. Bảng ?? so sánh với các phương pháp đã có kết quả công bố trên PHOENIX-2014. Các phương pháp không có kết quả trên PHOENIX-2014 (SignBT, CoSign) được bỏ qua.

Mô hình đạt WER nhất quán trên cả hai bộ dữ liệu (34,67/35,39% trên PHOENIX-2014T và 36,16/35,73% trên PHOENIX-2014), khẳng định kiến trúc ổn định khi chuyển sang bộ dữ liệu mới mà không cần tinh chỉnh siêu tham số. Trong nhóm keypoint-only, MSKA-SLR [?] là phương pháp dẫn đầu (21,7/22,1%); khoảng cách ~14 điểm WER so với chúng tôi phản ánh đánh đổi giữa độ chính xác và quy mô tham số, tương tự như đã thảo luận ở Mục ??.

4.7 Tốc độ suy luận

Bảng ?? báo cáo độ trễ suy luận trên một chuỗi keypoint giả lập với ba độ dài tiêu biểu, đo trên cùng GPU NVIDIA MX450 dùng để huấn luyện. Mỗi cấu hình được warm-up 10 lần và lấy trung bình 50 lần đo trong chế độ `torch.no_grad()`, batch size = 1.

Như Bảng ?? cho thấy, mô hình chạy nhanh hơn thời gian thực hàng trăm lần kể cả với những chuỗi tương đối dài, phản ánh chi phí tính toán rất thấp của kiến trúc keypoint-only. Sự dao động nhỏ ở giá trị $T = 100$ so với $T = 200$ chủ yếu đến từ overhead khởi tạo kernel CUDA tại các sequence ngắn.

Bảng 5: So sánh trên PHOENIX-2014. Số liệu lấy từ bài báo gốc hoặc Bảng 1 của Wang *et al.* [?].

Phương pháp	Modality	Dev WER (%)	Test WER (%)
<i>Nhóm video RGB:</i>			
STMC [?]	RGB	21,7	20,7
C2SLR [?]	RGB	20,5	20,4
SMKD [?]	RGB	20,8	21,0
SignBERT+ [?]	RGB	19,9	20,0
CorrNet [?]	RGB	18,8	19,4
TwoStream-SLR [?]	RGB + pose	18,4	18,8
<i>Nhóm keypoint-only:</i>			
TwoStream-SLR (keypoint) [?]	Pose	28,6	28,0
MSKA-SLR [?]	Pose (4 luồng)	21,7	22,1
Mô hình của chúng tôi	Keypoint (77)	36,16	35,73

Bảng 6: Độ trễ suy luận của mô hình theo độ dài chuỗi đầu vào, đo trên GPU NVIDIA MX450. Real-time factor được tính so với tốc độ khung hình 25 fps (tương đương fps đầu vào của PHOENIX-2014T).

Độ dài T (khung hình)	Latency (ms/seq)	Real-time factor
100 ($\approx$ 4,0 giây video)	11,6	$\sim 345\times$
200 ($\approx$ 8,0 giây video)	8,8	$\sim 914\times$
300 ($\approx$ 12,0 giây video)	9,4	$\sim 1\,276\times$

4.8 Phân tích kết quả và thảo luận

Vai trò của hợp nhất theo công. Hệ số α_t học được thể hiện đúng kỳ vọng định tính: ở các khung hình có cử chỉ tay rõ rệt, α cho `left/right_hand` tăng cao; ở các đoạn nói có mouthing, α cho `mouth` và `face` tăng tương ứng; luồng `pose` thường nhận trọng số trung bình, đóng vai trò context giúp giảm nhập nhằng giữa các sign cùng dạng tay khác vị trí thân.

Tác động của các nhánh aux. Việc dùng chung classifier giữa nhánh chính, nhánh visual và các nhánh per-stream buộc các bộ mã hóa phải sinh ra đặc trưng nằm cùng không gian ngữ nghĩa. Trong các phiên chạy trước, khi tắt aux, mô hình hội tụ chậm hơn rõ rệt và WER cao hơn 2–4 điểm phần trăm; điều này khẳng định vai trò regularization của giám sát đa cấp ở các mô hình quy mô nhỏ.

Khoảng cách dev–test. WER trên tập dev (34,67%) và test (35,39%) chỉ chênh nhau khoảng 0,7 điểm phần trăm, cho thấy mô hình không bị overfit theo tập dev: checkpoint được chọn theo dev WER nhưng phổ hóa được tới tập test. Điều này phù hợp với nhận xét chung rằng việc tăng cường giám sát phụ trợ (VAC + per-stream aux) hoạt động như một dạng regularization có hiệu quả trên các mô hình quy mô nhỏ.

Hạn chế. Dù WER $\sim 35\%$ là kết quả có ý nghĩa với mô hình 1,89M tham số, vẫn còn khoảng cách so với các mô hình SOTA trên cùng bộ dữ liệu — chủ yếu do (i) mô hình không tận dụng pixel RGB chứa thông tin biểu cảm vi tinh tế mà keypoint không bắt được, (ii) giải mã tham lam không khai thác cấu trúc thống kê của chuỗi gloss, và (iii) không có giai đoạn pretraining trên dữ liệu ngôn ngữ ký hiệu quy mô lớn. Các điểm này định hướng hướng cải tiến tiếp theo.

5 Kết luận

Trong nghiên cứu này, chúng tôi đã đề xuất một mô hình nhận dạng ngôn ngữ ký hiệu liên tục *cực nhẹ*, dựa hoàn toàn trên 77 keypoint mỗi khung hình và tổ chức theo năm modality giải phẫu được hợp nhất qua cơ chế cổng phụ thuộc thời gian. Với khoảng 1,89 triệu tham số và một chiến lược huấn luyện tích hợp Connectionist Temporal Classification cùng các nhánh giám sát phụ trợ kiểu VAC và per-stream, mô hình đạt WER 34,67% trên tập dev và 35,39% trên tập test PHOENIX-2014T *chỉ với một GPU NVIDIA MX450 2 GB VRAM trong khoảng 4 giờ huấn luyện*. Mô hình cũng được thẩm định trên PHOENIX-2014 (bản gốc) với cùng kiến trúc không thay đổi, đạt WER 36,16% (dev) và 35,73% (test), cho thấy khả năng tổng quát hóa tốt sang bộ dữ liệu mới. Kết quả này cho thấy một hướng đánh đổi mới trong CSLR: *trao đổi một phần độ chính xác tuyệt đối lấy mức giảm rất lớn về tham số và tài nguyên huấn luyện*, phù hợp với mục tiêu triển khai trên thiết bị biên và với các phòng thí nghiệm có tài nguyên hạn chế.

Còn nhiều hướng có thể tiếp tục cải thiện:

1. Bổ sung giải mã beam search và mô hình ngôn ngữ ở mức gloss, hai kỹ thuật chuẩn được nhiều nghiên cứu CSLR sử dụng nhằm khai thác cấu trúc thống kê của chuỗi gloss và đã cho thấy hiệu quả hỗ trợ cho CTC tham lam.
2. Pretrain tự giám sát trên keypoint quy mô lớn (theo hướng SignBERT) để tăng khả năng tổng quát hóa.
3. Tích hợp một nhánh RGB nhẹ (ví dụ MobileNet) song song với nhánh keypoint hiện tại, kết hợp qua chính kiến trúc gated fusion đã có để tận dụng cả tín hiệu thị giác và hình học.
4. Triển khai và đo độ trễ trên thiết bị di động/Jetson Nano để xác thực tính khả thi đầu cuối của hướng tiếp cận nhẹ.

Tài liệu

- [1] World Health Organization, *World report on hearing*, 2021.
- [2] N. C. Camgoz, S. Hadfield, O. Koller, H. Ney, R. Bowden, “Neural Sign Language Translation,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [3] Y. Min, A. Hao, X. Chai, X. Chen, “Visual Alignment Constraint for Continuous Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [4] A. Hao, Y. Min, X. Chen, “Self-Mutual Distillation Learning for Continuous Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [5] L. Hu, L. Gao, Z. Liu, W. Feng, “Continuous Sign Language Recognition with Correlation Network,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [6] Y. Chen, R. Zuo, F. Wei, Y. Wu, S. Liu, B. Mak, “Two-Stream Network for Sign Language Recognition and Translation,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [7] H. Hu, W. Zhao, W. Zhou, Y. Wang, H. Li, “SignBERT: Pre-Training of Hand-Model-Aware Representation for Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [8] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, Y. Sheikh, “OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2019.
- [9] C. Lugaresi *et al.*, “MediaPipe: A Framework for Building Perception Pipelines,” *arXiv preprint arXiv:1906.08172*, 2019.

- [10] S. Yan, Y. Xiong, D. Lin, “Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition,” in *AAAI Conference on Artificial Intelligence*, 2018.
- [11] A. van den Oord *et al.*, “WaveNet: A Generative Model for Raw Audio,” *arXiv preprint arXiv:1609.03499*, 2016.
- [12] S. Bai, J. Z. Kolter, V. Koltun, “An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling,” *arXiv preprint arXiv:1803.01271*, 2018.
- [13] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, Y. Bengio, “Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation,” in *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014.
- [14] A. Graves, S. Fernández, F. Gomez, J. Schmidhuber, “Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks,” in *International Conference on Machine Learning (ICML)*, 2006.
- [15] H. Zhou, W. Zhou, Y. Zhou, H. Li, “Spatial–Temporal Multi–Cue Network for Continuous Sign Language Recognition,” in *AAAI Conference on Artificial Intelligence*, 2020.
- [16] H. Zhou, W. Zhou, W. Qi, J. Pu, H. Li, “Improving Sign Language Translation with Monolingual Data by Sign Back–Translation,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [17] R. Zuo, B. Mak, “C2SLR: Consistency–Enhanced Continuous Sign Language Recognition,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [18] H. Hu, W. Zhao, W. Zhou, H. Li, “SignBERT+: Hand–Model–Aware Self–Supervised Pre–Training for Sign Language Understanding,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023.
- [19] S. Wang *et al.*, “Multi–Stream Keypoint Attention Network for Sign Language Recognition and Translation,” *arXiv preprint arXiv:2405.05672*, 2024.
- [20] P. Jiao, Y. Min, Y. Li, X. Wang, L. Lei, X. Chen, “CoSign: Exploring Co–occurrence Signals in Skeleton–based Continuous Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 20676–20686.