

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Nghiên cứu và đề xuất mô hình nhận diện ngôn ngữ
ký hiệu

Hoàng Đức Tấn

Tan.HD225924@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

Giảng viên hướng dẫn: PGS. TS. Phạm Văn Hải

Khoa: Khoa học máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2026

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Nghiên cứu và đề xuất mô hình nhận diện ngôn ngữ
ký hiệu

Hoàng Đức Tấn

Tan.HD225924@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin Việt-Nhật

Giảng viên hướng dẫn: PGS. TS. Phạm Văn Hải

Chữ kí GVHD

Khoa:

Khoa học máy tính

Trường:

Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2026

LỜI CẢM ƠN

Đầu tiên, em xin bày tỏ lòng biết ơn sâu sắc đến Đại học Bách Khoa Hà Nội, nơi đã cho em một môi trường giao lưu, học tập, làm việc, nghiên cứu tuyệt vời trong suốt quãng thời gian bốn năm qua. Đây thật sự là một quãng thời gian không thể quên đối với em, không chỉ được đào tạo bài bản cả về kiến thức chuyên môn, phong cách làm việc, nghiên cứu mà còn là nơi gặp gỡ và tiếp xúc được với những con người lớn, những người thầy để lại cho em bài học không chỉ trên ghế nhà trường mà có lẽ sẽ theo em suốt quãng đường tương lai sau này, những người bạn đồng hành đáng trân trọng. Em xin gửi lời tri ân đến toàn thể các thầy cô trong Trường Công nghệ thông tin và Truyền thông, những người đã dành rất nhiều tâm huyết, chia sẻ những kiến thức, kinh nghiệm quý báu cho em.

Đặc biệt, em xin chân thành cảm ơn PGS. TS. Phạm Văn Hải, và TS. Ngô Thành Trung đã tạo điều kiện đồng hướng dẫn cho em đồ án tốt nghiệp kì này. Dưới sự hướng dẫn của thầy, em đã học được rất nhiều kiến thức và kinh nghiệm hữu ích về làm việc thực tế và nghiên cứu khoa học. Sự hướng dẫn tận tình của thầy không chỉ giúp em định hướng mà còn giúp em vượt qua những khó khăn trong quá trình nghiên cứu, là nguồn động viên lớn đối với em. Thêm một lần nữa, em xin bày tỏ lòng biết ơn chân thành và sâu sắc đến hai thầy vì sự hướng dẫn, giúp đỡ tận tình của hai thầy trong thời gian qua. Chúc hai thầy luôn luôn mạnh khỏe, gặt hái được nhiều thành công trong công việc, tiếp tục đóng góp sự nghiệp nghiên cứu và giảng dạy ngày càng đào tạo ra được thế hệ tương lai tài giỏi hơn.

Cuối cùng, con xin trân thành cảm ơn đến bố mẹ, gia đình là nguồn động lực lớn lao để con cố gắng và nỗ lực trong những năm tháng qua, là chỗ dựa vững chắc mỗi khi con gặp khó khăn, những lời động viên, quan tâm vô điều kiện của gia đình chính đã tác động rất lớn đến việc hình thành con của ngày hôm nay và cũng ảnh hưởng rất lớn đến con của tương lai.

TÓM TẮT NỘI DUNG ĐỒ ÁN

Hiện nay với số lượng lớn người trên thế giới bị khiếm thính, khiếm thị thì bài toán giao tiếp đối với người khiếm thính, khiếm thị đang là bài toán được quan tâm và một trong những cách để giải quyết bài toán đó là nhận diện ngôn ngữ ký hiệu - là ngôn ngữ giao tiếp bằng các cử động của tay, chân, cơ thể, mặt, ... Thực tế do các mô hình mạng nơ-ron hiện tại cho bài toán nhận diện ngôn ngữ ký hiệu rất lớn gây khó khăn trong việc người khiếm thính/ khiếm thị tiếp cận. Nhận thấy hạn chế đó, dự án lựa chọn hướng tiếp cận là xây dựng mô hình nhẹ, dễ tích hợp vào trong các thiết bị biên để giúp mọi người tiếp cận dễ hơn, giải quyết được bài toán giao tiếp của người khiếm thính, khiếm thị.

Đồ án đề xuất một mô hình nhận dạng ngôn ngữ ký hiệu liên tục dựa trên đặc trưng keypoint với kiến trúc đa luồng. Đầu tiên, đồ án sử dụng bộ keypoint được trích xuất sẵn bởi HRNet từ các bộ dữ liệu chuẩn (Phoenix-2014T), sau đó chia ra thành các điểm keypoint theo các vùng bao gồm: tay trái, tay phải, miệng, mặt và thân, đồng thời có thêm các đặc trưng vận tốc tay chuyển động giữa các khung hình để lấy làm thông tin chuyển động tức thời. Tiếp theo, một bộ mã hóa từng luồng riêng biệt được đề xuất cho mỗi vùng, tiếp theo là lớp BiGRU để học phụ thuộc thời gian cục bộ. Sau đó là cơ chế Gated Fusion được đề xuất để hợp nhất đặc trưng từ năm luồng thông qua trọng số chú ý phụ thuộc thời gian được học từ dữ liệu, nhằm ưu tiên các luồng quan trọng (tay trái, tay phải, miệng) theo từng thời điểm cụ thể. Tiếp theo sau là BiGRU hai lớp nhằm mã hóa ngữ cảnh thời gian toàn câu do lớp BiGRU trước đó chỉ mã hóa được ngữ cảnh của một chuỗi thời gian ngắn, trước khi đưa qua đầu phân lớp CTC để sinh ra chuỗi gloss đầu ra.

Để kiểm chứng kết quả của mô hình đề xuất, mô hình được huấn luyện trên bộ dữ liệu chuẩn Phoenix-2014T với hàng đo đánh giá chính là Word Error Rate (WER). Kết quả thực nghiệm cho thấy mô hình đề xuất đạt được kết quả chấp nhận được so với các phương pháp gần đây, trong khi giữ được số lượng tham số ít, phù hợp với yêu cầu triển khai trên thiết bị tài nguyên hạn chế. Trong tương lai, đồ án sẽ tiếp tục được tinh chỉnh và đánh giá để nâng cao hiệu quả và tính ứng dụng thực tiễn của mô hình trong các ứng dụng nhận diện ngôn ngữ ký hiệu.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

ABSTRACT

Currently, with a large number of people worldwide suffering from hearing and visual impairments, communication for the deaf and hard-of-hearing remains a significant challenge. One of the key solutions to address this problem is sign language recognition — a communication language expressed through movements of the hands, body, face, and other body parts. In practice, existing neural network models for sign language recognition tend to be very large, making them difficult for people with hearing or visual impairments to access. Recognizing this limitation, this project adopts the approach of building a lightweight model that can be easily integrated into edge devices, thereby lowering the barrier to access and addressing the communication needs of the hearing- and visually-impaired community.

This thesis proposes a continuous sign language recognition model based on keypoint features with a multi-stream architecture. First, the model uses keypoints pre-extracted by HRNet from the standard Phoenix-2014T dataset, then splits them into anatomical regions including: left hand, right hand, mouth, face, and body. Hand velocity features between consecutive frames are also incorporated to capture instantaneous motion information. Next, a separate per-stream encoder is proposed for each region, followed by a BiGRU layer to model local temporal dependencies. A Gated Fusion mechanism is then applied to merge features from all five streams via time-dependent attention weights learned from data, allowing the model to dynamically prioritize the most informative streams (left hand, right hand, mouth) at each timestep. This is followed by a two-layer BiGRU to encode sentence-level temporal context, since the earlier per-stream BiGRU only captures short-range temporal dependencies, before passing through a CTC classification head to produce the output gloss sequence.

To validate the proposed model, it is trained and evaluated on the Phoenix-2014T benchmark dataset using Word Error Rate (WER) as the primary metric. Experimental results show that the proposed model achieves acceptable performance compared to recent methods while maintaining a small parameter count, making it suitable for deployment on resource-constrained edge devices. In the future, the model will continue to be refined and evaluated to further improve its effectiveness and practical applicability in sign language recognition applications.

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Đặt vấn đề.....	1
1.2 Các giải pháp hiện tại và hạn chế	2
1.3 Phạm vi nghiên cứu	3
1.4 Mục tiêu và định hướng giải pháp	3
1.5 Đóng góp của đề án	4
1.6 Bố cục đề án	4
CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT	6
2.1 Ngữ cảnh của bài toán.....	6
2.1.1 Định nghĩa bài toán	6
2.1.2 Thách thức đặc trưng	7
2.1.3 Ý nghĩa ứng dụng.....	8
2.1.4 Trích xuất đặc trưng tư thế người (Pose Estimation).....	8
2.2 Các kết quả nghiên cứu tương tự	8
2.2.1 Phương pháp dựa trên đặc trưng ảnh RGB	9
2.2.2 Phương pháp dựa trên đặc trưng keypoint/skeleton	9
2.2.3 Phương pháp kết hợp đa phương thức.....	9
2.2.4 Tổng hợp so sánh các hướng tiếp cận	9
2.2.5 Động lực của đề án	10
2.3 Mô hình mạng nơ-ron cho chuỗi thời gian.....	10
2.3.1 Mạng tích chập giãn nở (Dilated TCN).....	10
2.3.2 Tích chập phân tách theo chiều sâu (Depthwise-Separable Convolution).....	11
2.3.3 Mạng hồi tiếp hai chiều (BiGRU)	13

2.3.4 Chuẩn hóa lớp và kết nối tắt	15
2.4 Hàm mất mát CTC và nhận dạng chuỗi không phân đoạn.....	16
2.4.1 Bài toán căn chỉnh chuỗi.....	16
2.4.2 Connectionist Temporal Classification (CTC).....	16
2.4.3 Giải mã tham lam (Greedy Decoding).....	17
2.4.4 Ưu điểm của CTC so với các phương pháp căn chỉnh khác.....	17
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT.....	19
3.1 Phương pháp đề xuất.....	19
3.1.1 Tổng quan kiến trúc.....	19
3.1.2 Tiền xử lý và biểu diễn keypoint	19
3.1.3 Luận chứng lựa chọn phân vùng năm luồng giải phẫu.....	20
3.1.4 Bộ mã hóa từng luồng	21
3.1.5 Hợp nhất theo cổng phụ thuộc thời gian	22
3.1.6 Tinh chỉnh thời gian và đầu CTC	23
3.1.7 Hàm mất mát.....	24
3.1.8 Giải mã suy luận.....	24
3.1.9 Tổng kết các lựa chọn thiết kế và so sánh với phương án thay thế....	24
3.1.10 Phân tích độ phức tạp tính toán.....	25
CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM.....	27
4.1 Dữ liệu thực nghiệm	27
4.1.1 Bộ dữ liệu Phoenix-2014	27
4.1.2 Bộ dữ liệu Phoenix-2014T	27
4.1.3 So sánh hai bộ dữ liệu.....	28
4.1.4 Tiền xử lý keypoint	28
4.2 Tham số đánh giá	29

4.3 Cài đặt thực nghiệm	29
4.3.1 Môi trường phần cứng và phần mềm	29
4.3.2 Siêu tham số huấn luyện	30
4.3.3 Tăng cường dữ liệu.....	30
4.4 Các phương pháp so sánh	31
4.5 Kết quả thực nghiệm chính	32
4.6 Nghiên cứu loại bỏ thành phần.....	33
4.7 Phân tích và thảo luận	34
4.7.1 Phân tích lỗi	34
4.7.2 Phân tích chi phí tính toán.....	35
4.7.3 So sánh với phương án thiết kế thay thế.....	36
4.7.4 Phân tích hội tụ quá trình huấn luyện	36
4.7.5 Phân tích hành vi trọng số hợp nhất	36
4.7.6 Hạn chế.....	38
CHƯƠNG 5. KẾT LUẬN	39
5.1 Kết luận	39
5.2 Hướng phát triển trong tương lai	40
TÀI LIỆU THAM KHẢO.....	46

DANH MỤC HÌNH VẼ

Hình 2.1	Sơ đồ tổng quan của bài toán Continuous Sign Language Recognition	6
Hình 2.2	Hình minh họa cho độ dài chuỗi không đồng nhất giữa các ký hiệu và biến thể giữ người ký	7
Hình 2.3	Mô phỏng kiến trúc của mạng Dilated TCN	11
Hình 2.4	Mạng Dilated TCN đồ án sử dụng	12
Hình 2.5	So sánh Tích chập 1D tiêu chuẩn (a) và Depthwise-Separable Convolution (b).	13
Hình 2.6	Kiến trúc mạng BiGRU tổng quát. Đầu vào được ánh xạ qua tầng Embedding trước khi đưa vào hai luồng GRU song song: Forward GRU ($\overrightarrow{GRU}$) xử lý chuỗi từ trái sang phải và Backward GRU ($\overleftarrow{GRU}$) xử lý từ phải sang trái qua T bước thời gian. Đầu ra của hai luồng tại mỗi bước được nối (Concatenate) thành vector đặc trưng kết hợp mang ngữ cảnh cả hai chiều, sau đó qua các tầng Dense để tạo ra đầu ra cuối cùng.	14
Hình 2.7	Ví dụ minh họa CTC: chuỗi đầu vào $T=9$ khung hình được căn chỉnh với chuỗi nhãn mở rộng “ $\emptyset A \emptyset B \emptyset$ ” (xen blank giữa các gloss). Đường tô đậm cho thấy một căn chỉnh hợp lệ ($\emptyset, A, A, A, \emptyset, B, B, B, \emptyset$) – sau khi xóa nhãn lặp và blank cho kết quả “A B”. CTC tổng hợp xác suất trên <i>tất cả</i> đường hợp lệ nên không yêu cầu chọn trước một căn chỉnh cụ thể.	16
Hình 3.1	Sơ đồ tổng quan của mô hình đề xuất. Năm luồng giải phẫu được mã hóa độc lập, hợp nhất qua cổng phụ thuộc thời gian, tinh chỉnh thời gian và phân lớp bằng CTC.	19
Hình 3.2	Sơ đồ cơ chế Gated Fusion phụ thuộc thời gian. Năm vector đặc trưng luồng (128-d mỗi luồng) được nối thành vector 640-d, đưa qua MLP ($640 \rightarrow 320 \rightarrow 5$) và softmax để học trọng số đóng góp α_t tại từng khung hình t . Đặc trưng hợp nhất f_t là tổng có trọng số qua Layer Normalization.	23
Hình 4.1	Minh họa bốn kỹ thuật tăng cường dữ liệu trên keypoint bàn tay: (a) keypoint gốc; (b) temporal resampling – hai frame ở tốc độ khác nhau (xanh đậm: frame gốc, đỏ: frame giãn thời gian); (c) nhiễu Gaussian thêm vào tọa độ (x, y) ; (d) xoay 2D ngẫu nhiên quanh tâm bounding box (xanh mờ: gốc, tím: sau xoay).	30

Hình 4.2 Đường cong huấn luyện trên Phoenix-2014T: Dev WER (đỏ) và Train WER (xanh) theo epoch. Vùng cam: giai đoạn hội tụ nhanh (epoch 1–80); vùng xanh: giai đoạn tinh chỉnh (epoch 81–200). Dấu chấm đánh dấu checkpoint tốt nhất tại epoch 178 với Dev WER = 34,67%. 37

DANH MỤC BẢNG BIỂU

Bảng 2.1	So sánh tổng hợp các hướng tiếp cận CSLR.	10
Bảng 2.2	So sánh các phương pháp nhận dạng chuỗi cho bài toán CSLR.	18
Bảng 3.1	Phân bố 77 keypoint theo năm luồng giải phẫu.	20
Bảng 3.2	Vai trò ngữ nghĩa và cấu hình giám sát của năm luồng giải phẫu.	21
Bảng 3.3	Tổng hợp lựa chọn thiết kế và phương án thay thế được cân nhắc.	25
Bảng 3.4	Phân tích số tham số theo từng thành phần kiến trúc.	25
Bảng 4.1	Thống kê bộ dữ liệu Phoenix-2014.	27
Bảng 4.2	Thống kê bộ dữ liệu Phoenix-2014T.	28
Bảng 4.3	So sánh Phoenix-2014 và Phoenix-2014T.	28
Bảng 4.4	Phân vùng 77 keypoint thành 5 luồng giải phẫu.	29
Bảng 4.5	Cấu hình thực nghiệm chi tiết.	30
Bảng 4.6	Siêu tham số huấn luyện của mô hình đề xuất.	31
Bảng 4.7	So sánh WER (%) trên Phoenix-2014T.	32
Bảng 4.8	So sánh WER (%) trên Phoenix-2014.	33
Bảng 4.9	Ablation study trên tập Test Phoenix-2014T (WER %).	33
Bảng 4.10	Ước tính phân bố ba loại lỗi WER trên tập Dev Phoenix-2014T.	35
Bảng 4.11	So sánh chi phí tài nguyên giữa hai nhóm phương pháp CSLR.	35

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề

Trong xã hội hiện đại ngày nay, ngôn ngữ không chỉ là công cụ giao tiếp mà còn là cầu nối để cá nhân tiếp cận tri thức, việc làm và hòa nhập cộng đồng. Tuy nhiên, đối với cộng đồng người khiếm thính và khiếm thị trên toàn cầu – với con số lên đến hàng trăm triệu người theo thống kê của Tổ chức Y tế Thế giới (WHO) – rào cản về ngôn ngữ vẫn là một thách thức trong xã hội hiện đại ngày nay. Ngôn ngữ ký hiệu (Sign Language), hệ thống ngôn ngữ sử dụng các chuyển động hình thể phức tạp từ bàn tay, cánh tay đến biểu cảm khuôn mặt, chính là phương thức biểu đạt suy nghĩ duy nhất của những người khiếm thính, khiếm thị. Dù vậy, sự thiếu hụt trong nhân sự đội ngũ phiên dịch viên chuyên nghiệp cho ngôn ngữ ký hiệu cùng sự khác biệt trong giao tiếp của những người bình thường và người khiếm thính, khiếm thị đã vô tình tạo ra một khoảng cách giao tiếp giữa người bình thường và người khiếm thính, khiếm thị.

Thực tế cho thấy, việc nghiên cứu các hệ thống nhận diện ngôn ngữ ký hiệu tự động (SLR) không phải là một đề tài mới. Trong những năm gần đây, sự bùng nổ của trí tuệ nhân tạo (AI) và các mô hình mạng nơ-ron sâu (Deep Learning) đã đem lại những bước tiến vượt bậc về độ chính xác trong việc chuyển đổi ký hiệu thành văn bản hoặc tiếng nói. Tuy nhiên, các mô hình đạt hiệu suất cao nhất hiện nay thường sở hữu cấu trúc mạng cực kỳ đồ sộ với hàng triệu tham số, đòi hỏi tài nguyên tính toán khổng lồ từ các hệ thống máy chủ hoặc GPU chuyên dụng. Điều này khiến việc triển khai chúng vào thực tiễn đời sống – nơi người dùng cần sự phản hồi tức thời trên các thiết bị cá nhân – trở nên bất khả thi do độ trễ và yêu cầu tài nguyên quá lớn.

Đối với người khiếm thính và khiếm thị, một công cụ hỗ trợ giao tiếp chỉ có giá trị khi nó mang tính di động (mobility) và sẵn sàng (availability) do việc giao tiếp diễn ra hằng ngày và liên tục. Việc phải phụ thuộc vào kết nối đám mây hoặc các thiết bị phần cứng đắt tiền không chỉ gây khó khăn về mặt tài chính mà còn làm giảm tính riêng tư và linh hoạt trong giao tiếp hàng ngày. Thách thức lớn nhất hiện nay không còn nằm ở việc làm sao để mô hình chính xác, mà là làm sao để mô hình vừa chính xác, vừa nhẹ để vận hành tốt mà trên các thiết bị di động có cấu hình hạn chế.

Xuất phát từ nhu cầu nhân văn và cấp thiết trên, đề án lựa chọn hướng tiếp cận Xây dựng mô hình học máy tối ưu hóa hiệu năng, tập trung vào việc thiết kế kiến trúc mạng nơ-ron nhẹ (Lightweight Models) chuyên biệt cho bài toán nhận diện

ngôn ngữ ký hiệu. Mục tiêu của nghiên cứu là tạo ra một giải pháp cân bằng hoàn hảo giữa độ chính xác và tốc độ xử lý, cho phép tích hợp trực tiếp vào ứng dụng di động. Mục tiêu góp phần xóa bỏ rào cản về giao tiếp của những người bình thường và người khiếm thính, khiếm thị.

1.2 Các giải pháp hiện tại và hạn chế

Trong nỗ lực thu hẹp khoảng cách giao tiếp cho người khiếm thính, các nghiên cứu về Dịch thuật Ngôn ngữ Ký hiệu (Sign Language Translation - SLT) đã phát triển qua nhiều giai đoạn với những bước đột phá về kiến trúc mô hình. Nhìn chung, các giải pháp hiện nay có thể được phân loại thành ba hướng tiếp cận chính:

Hướng tiếp cận phân tầng (Cascading Methods) - Đây là phương pháp truyền thống nhưng vẫn giữ vai trò quan trọng, tiêu biểu với các nghiên cứu như mạng nơ-ron trong dịch ngôn ngữ ký hiệu (Neural Sign Language Translation – NSLT (2018)) hay dịch thuật ngôn ngữ ký hiệu bằng transformer (Sign Language Recognition Transformer – SLRT (2020)). Giải pháp này chia bài toán thành hai giai đoạn tách biệt: đầu tiên là nhận diện ký hiệu (Sign Language Recognition) là dịch từng 1 đoạn video ngắn tạo ra các từ khóa trung gian (Gloss), sau đó sử dụng các mô hình dịch thuật ngôn ngữ tự nhiên (Neural Machine Translation – NMT) để chuyển đổi sang câu văn hoàn chỉnh. Mặc dù giúp mô hình dễ kiểm soát và tận dụng được các bộ dữ liệu Gloss sẵn có, nhưng phương pháp phân tầng thường gặp phải hiện tượng tích tụ sai số (error propagation). Nếu giai đoạn nhận diện ban đầu sai lệch, toàn bộ ngữ nghĩa của câu dịch phía sau sẽ bị biến đổi, gây khó khăn cho việc duy trì tính chính xác trong môi trường thực tế.

Hướng tiếp cận tích hợp dựa trên từ trung gian (Gloss) (Gloss-based End-to-end) - Để khắc phục nhược điểm của phương pháp phân tầng, các mô hình tích hợp (End-to-end) đã ra đời. Các kỹ thuật như TwoStream-SLT (2022) hay gần đây là SEDA (2024) tập trung vào việc huấn luyện đồng thời việc trích xuất đặc trưng và dịch thuật. Việc sử dụng "Gloss" làm tín hiệu giám sát trung gian giúp mô hình học được các đơn vị ngữ nghĩa nhỏ nhất của ký hiệu tay. Tuy nhiên, sự phụ thuộc vào dữ liệu được gán nhãn Gloss cực kỳ chi tiết là một điểm nghẽn đối với bài toán này, vì chi phí gán nhãn thủ công cho các bộ dữ liệu này là rất cao, đồng thời cấu trúc này vẫn còn khá nặng nề, khó triển khai trực tiếp trên các thiết bị đầu cuối.

Hướng tiếp cận phi từ trung gian (Gloss-free Methods) - Xu hướng mới nhất trong giai đoạn 2023-2024 hướng tới việc loại bỏ hoàn toàn sự phụ thuộc vào Gloss, tiêu biểu với các mô hình như SignLLM (2024) hay Sign2GPT (2024). Các giải pháp này tận dụng sức mạnh của các Mô hình ngôn ngữ lớn (LLM) để dịch trực tiếp từ video ký hiệu sang văn bản. Ưu điểm vượt trội của hướng đi này là khả

năng hiểu ngữ cảnh sâu sắc và tạo ra câu văn tự nhiên hơn. Thế nhưng, cái giá phải trả là sự gia tăng đột biến về kích thước mô hình và yêu cầu khắt khe về phần cứng tính toán. Các mô hình như SignLLM dù đạt hiệu suất ấn tượng nhưng lại đi ngược lại mục tiêu tiếp cận phổ quát trên thiết bị di động do độ phức tạp của mạng nơ-ron quá lớn.

1.3 Phạm vi nghiên cứu

Để đảm bảo tính khả thi của thực hiện đề án, phạm vi nghiên cứu được xác định cụ thể như sau:

Về bài toán, đề án là 1 nửa đầu trong luồng của hướng tiếp cận phân tầng: Cascading Methods, do xác định tầm quan trọng của việc nhân ra ngôn ngữ trung gian để làm bước đệm cho giai đoạn dịch thuật ra văn bản đời thường, đề án tập trung vào bài toán nhận dạng ngôn ngữ ký hiệu liên tục (CSLR) ở cấp độ gloss, là đầu ra của mô hình là chuỗi ký hiệu từ vựng trung gian (gloss sequence), chưa bao gồm giai đoạn dịch thuật sang câu ngôn ngữ tự nhiên hoàn chỉnh (Sign Language Translation – SLT). Việc tách riêng hai giai đoạn này cho phép đánh giá độc lập chất lượng nhận dạng ký hiệu thông qua thang đo WER đã được chuẩn hóa trong cộng đồng nghiên cứu quốc tế.

Về dữ liệu, thực nghiệm được tiến hành trên hai bộ dữ liệu thuộc họ RWTH-PHOENIX-Weather với ngôn ngữ ký hiệu Đức (Deutsche Gebärdensprache – DGS): **Phoenix-2014** (5.672 mẫu train, từ vựng 1.232 gloss) và **Phoenix-2014T** (7.094 mẫu train, từ vựng 1.124 gloss). Cả hai bộ dữ liệu chia sẻ cùng quy trình tiền xử lý keypoint, cho phép đánh giá khả năng tổng quát hóa của kiến trúc của mô hình. Khả năng tổng quát sang các ngôn ngữ ký hiệu khác (ngôn ngữ ký hiệu Việt Nam, Mỹ, ...) chưa được kiểm chứng trong phạm vi đề án này.

Về phần cứng mục tiêu, đề án hướng tới các thiết bị có GPU dưới 4 GB VRAM, được minh chứng bằng việc huấn luyện thành công trên GPU NVIDIA MX450 2 GB. Tối ưu hóa cho CPU-only hoặc thiết bị nhúng không có GPU chưa nằm trong phạm vi đề án này.

1.4 Mục tiêu và định hướng giải pháp

Mục tiêu chính của đề án là xây dựng một mô hình nhận dạng ngôn ngữ ký hiệu liên tục nhẹ có thể triển khai trên thiết bị di động, thiết bị biên và đạt độ chính xác chấp nhận được so với các mô hình hiện đại. Cụ thể, các mục tiêu chính bao gồm:

Thứ nhất, sử dụng bộ keypoint được trích xuất sẵn bởi HRNet từ bộ dữ liệu chuẩn Phoenix-2014T và Phoenix-2014, sau đó phân chia thành các vùng giải phẫu độc lập (tay trái, tay phải, miệng, mặt, thân) kết hợp đặc trưng vận tốc giữa các khung

hình nhằm giảm chi phí tính toán so với phương pháp xử lý ảnh trực tiếp.

Tiếp theo, đề xuất một bộ mã hóa đa luồng (Multi-stream Encoder), trong đó mỗi luồng giải phẫu được mã hóa độc lập qua lớp chiếu tuyến tính, mạng tích chập giãn nở TCN và lớp BiGRU, nhằm khai thác đặc trưng thời gian cục bộ đặc thù của từng vùng cơ thể.

Sau đó là đề xuất cơ chế Gated Fusion để hợp nhất đặc trưng từ năm luồng thông qua trọng số chú ý phụ thuộc thời gian được học từ dữ liệu, giúp mô hình tự động ưu tiên các luồng mang nhiều thông tin ngữ nghĩa hơn (tay trái, tay phải, miệng) tại từng thời điểm cụ thể.

Mô hình được đánh giá hiệu quả của mô hình đề xuất trên bộ dữ liệu chuẩn Phoenix-2014T và Phoenix-2014 theo thang đo Word Error Rate (WER), so sánh kết quả của mô hình đề xuất với các phương pháp hiện đại khác trong cùng lĩnh vực nhận dạng ngôn ngữ ký hiệu liên tục.

1.5 Đóng góp của đề án

Đề án này có 3 đóng góp chính như sau:

Thứ nhất, Đề xuất kiến trúc mã hóa đa luồng giải phẫu (Multi-stream Anatomical Encoder) kết hợp đặc trưng vận tốc tức thời, trong đó mỗi vùng cơ thể được mã hóa độc lập qua TCN giãn nở và BiGRU, cho phép mô hình học đặc trưng thời gian cục bộ riêng biệt cho từng bộ phận tham gia ký hiệu.

Thứ hai, Đề xuất cơ chế Gated Fusion phụ thuộc thời gian, học trọng số chú ý động từ dữ liệu nhằm hợp nhất đặc trưng từ năm luồng một cách linh hoạt, thay thế cho phương pháp nối ghép (concatenation) tĩnh thông thường.

Thứ ba, Xây dựng một mô hình CSLR nhẹ (khoảng 1,9M tham số) đạt kết quả cạnh tranh trên bộ dữ liệu chuẩn Phoenix-2014T và Phoenix-2014, chứng minh tính khả thi của hướng tiếp cận dựa trên keypoint cho bài toán nhận dạng ngôn ngữ ký hiệu liên tục trên thiết bị tài nguyên hạn chế.

1.6 Bố cục đề án

Đề án được trình bày rõ ràng và có hệ thống mô hình đề xuất, đề án được tổ chức thành 5 chương.

Chương 2 trình bày các nền tảng lý thuyết cần thiết, bao gồm bài toán CSLR và các thách thức đặc trưng, mô hình ước lượng tư thế HRNet, mạng nơ-ron hồi tiếp hai chiều (BiGRU), mạng tích chập giãn nở (Dilated TCN), tích chập phân tách theo chiều sâu (DSConv), chuẩn hóa lớp, kết nối tắt và hàm mất mát CTC dùng trong nhận dạng chuỗi không phân đoạn. Phần khảo sát các nghiên cứu liên quan

phân tích ưu nhược điểm của ba nhóm phương pháp CSLR hiện tại, từ đó làm rõ động lực thiết kế của đề án.

Trong Chương 3, chúng tôi trình bày chi tiết kiến trúc mô hình đề xuất, bao gồm luận chứng phân vùng năm luồng giải phẫu, phương pháp tiền xử lý và tăng cường dữ liệu keypoint, bộ mã hóa đa luồng với Dilated TCN và BiGRU, cơ chế Gated Fusion phụ thuộc thời gian, BiGRU tinh chỉnh ngữ cảnh câu, đầu phân lớp CTC đa nhánh và phân tích độ phức tạp tính toán.

Chương 4 trình bày toàn bộ quá trình thực nghiệm, bao gồm mô tả hai bộ dữ liệu Phoenix-2014 và Phoenix-2014T, các thang đo đánh giá, chi tiết cài đặt huấn luyện, kết quả so sánh với các phương pháp liên quan, nghiên cứu loại bỏ thành phần (ablation study) và phân tích chuyên sâu về lỗi và hành vi hợp nhất.

Chương 5 đưa ra kết luận về những kết quả đạt được, phân tích hạn chế còn tồn tại và đề xuất các hướng nghiên cứu phát triển trong tương lai.

Tóm tắt chương. Chương này đã phân tích bối cảnh thực tiễn của bài toán nhận dạng ngôn ngữ ký hiệu liên tục, chỉ ra hạn chế chính của các hệ thống CSLR hiện tại về chi phí tính toán và khả năng triển khai trên thiết bị biên. Từ đó, đề án xác định mục tiêu, phạm vi và ba đóng góp cốt lõi: kiến trúc đa luồng giải phẫu, cơ chế Gated Fusion phụ thuộc thời gian, và mô hình CSLR nhẹ đạt kết quả cạnh tranh trên hai bộ dữ liệu chuẩn DGS với chưa đến 2M tham số. Bố cục chi tiết của từng chương tiếp theo được trình bày để định hướng cho người đọc.


CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT

Chương này trình bày nền tảng lý thuyết và bối cảnh nghiên cứu của đề án. Phần đầu phân tích ngữ cảnh bài toán nhận dạng ngôn ngữ ký hiệu liên tục, bao gồm định nghĩa bài toán, các thách thức đặc trưng và ý nghĩa ứng dụng thực tiễn. Tiếp theo, phần khảo sát các nghiên cứu liên quan phân tích ưu nhược điểm của các hướng tiếp cận hiện có, từ đó làm rõ động lực cho giải pháp đề xuất trong đề án. Hai phần cuối trình bày hai nhóm kiến thức nền tảng có liên quan mật thiết nhất: mô hình mạng nơ-ron cho chuỗi thời gian (TCN và BiGRU) và hàm mất mát CTC dùng trong nhận dạng chuỗi không phân đoạn.

2.1 Ngữ cảnh của bài toán

2.1.1 Định nghĩa bài toán

Nhận dạng ngôn ngữ ký hiệu liên tục (Continuous Sign Language Recognition – CSLR) là bài toán ánh xạ một đoạn video ngôn ngữ ký hiệu chưa được phân đoạn sang chuỗi gloss tương ứng, trong đó mỗi gloss là một nhãn cấp từ vựng đại diện cho ngữ nghĩa của một ký hiệu. Không giống bài toán nhận dạng ký hiệu đơn lẻ (Isolated SLR), CSLR phải xử lý chuỗi ký hiệu liên tiếp với độ dài thay đổi, không có ranh giới cứng giữa các ký hiệu và thời lượng thực hiện mỗi ký hiệu không đồng đều giữa các người ký. Tham khảo hình 2.1



Hình 2.1: Sơ đồ tổng quan của bài toán Continuous Sign Language Recognition

Đầu vào của bài toán là chuỗi video $V = \{v_1, v_2, \dots, v_T\}$ gồm T khung hình.

Đầu ra là chuỗi gloss $\mathbf{g} = (g_1, g_2, \dots, g_N)$ với $N \ll T$, thuộc vốn từ vựng $\mathcal{G}$ cố định. Thách thức cốt lõi nằm ở chỗ mô hình cần học cách căn chỉnh chuỗi khung hình với chuỗi nhãn mà không cần thông tin phân đoạn thời gian trong quá trình huấn luyện.

2.1.2 Thách thức đặc trưng

Bài toán CSLR đặt ra một số thách thức đặc thù so với các bài toán nhận dạng chuỗi thông thường:

- **Độ dài chuỗi không đồng nhất:** Mỗi câu ký hiệu có thể kéo dài từ vài giây đến hàng chục giây, trong khi số lượng gloss tương ứng dao động lớn, khiến việc căn chỉnh thời gian trở nên phức tạp.
- **Co-articulation:** Các ký hiệu liên kế ảnh hưởng lẫn nhau về hình dạng tay và vị trí cơ thể, gây ra hiện tượng biến dạng ranh giới giữa các gloss.
- **Biến thể giữa người ký:** Tốc độ thực hiện, phong cách ký và kích thước cơ thể khác nhau đáng kể giữa các cá nhân.
- **Chi phí tính toán:** Các mô hình dựa trên đặc trưng hình ảnh trực tiếp (RGB frames) đòi hỏi bộ nhớ và thời gian suy luận lớn, gây khó khăn khi triển khai trên thiết bị biên. Tham khảo hình 2.2.



Hình 2.2: Hình minh họa cho độ dài chuỗi không đồng nhất giữa các ký hiệu và biến thể giữa người ký

2.1.3 Ý nghĩa ứng dụng

Theo Tổ chức Y tế Thế giới (WHO), có hơn 1,5 tỷ người trên toàn cầu bị suy giảm thính lực ở các mức độ khác nhau [1]. Ngôn ngữ ký hiệu là phương tiện giao tiếp tự nhiên của cộng đồng người khiếm thính, song rào cản ngôn ngữ với đa số người nghe bình thường vẫn còn lớn. Một hệ thống CSLR hoạt động thời gian thực trên thiết bị di động có thể đóng vai trò phiên dịch tự động, góp phần xóa bỏ rào cản giao tiếp này mà không cần thông dịch viên.

2.1.4 Trích xuất đặc trưng tư thế người (Pose Estimation)

Trong pipeline của đề án, dữ liệu đầu vào không phải ảnh RGB thô mà là tọa độ keypoint đã được trích xuất sẵn bằng mô hình ước lượng tư thế người (pose estimation). Bài toán ước lượng tư thế người là bài toán xác định vị trí không gian của các khớp xương (joints) trên cơ thể người từ ảnh hoặc video, đóng vai trò cầu nối giữa dữ liệu thô và biểu diễn có cấu trúc dùng trong các tầng mô hình phía sau.

HRNet (High-Resolution Representation Network) [2] là kiến trúc ước lượng tư thế đạt hiệu suất hàng đầu. Điểm đặc trưng của HRNet là duy trì các nhánh biểu diễn độ phân giải cao xuyên suốt toàn bộ mạng, thay vì khôi phục độ phân giải từ biểu diễn thấp như các kiến trúc trước đó (Stacked Hourglass, SimpleBaseline). Cụ thể, HRNet kết nối song song nhiều nhánh ở các độ phân giải khác nhau và trao đổi thông tin liên tục giữa các nhánh qua các khối fusion đa tỉ lệ, cho phép học đồng thời đặc trưng ngữ nghĩa cấp cao và đặc trưng vị trí cấp thấp với độ chính xác không gian cao.

Trong bối cảnh của đề án, keypoint được HRNet trích xuất từ từng khung hình video, bao gồm 77 điểm bao phủ thân người, hai bàn tay, miệng và vùng khuôn mặt. Việc sử dụng keypoint thay vì ảnh RGB mang lại ba lợi thế chính:

1. Chiều dữ liệu giảm từ $H \times W \times 3$ (hàng chục nghìn giá trị) xuống 77×3 (231 giá trị) trên mỗi khung hình, giảm đáng kể chi phí tính toán và bộ nhớ.
2. Biểu diễn bất biến với các yếu tố ngoại cảnh như màu sắc, độ sáng và nền ảnh, người ký hiệu, giúp mô hình tập trung vào thông tin chuyển động và hình thái ký hiệu.
3. Tương thích trực tiếp với các mô hình chuỗi thời gian nhẹ mà không cần backbone CNN xử lý ảnh tốn kém.

2.2 Các kết quả nghiên cứu tương tự

Các nghiên cứu về CSLR có thể phân thành ba nhóm chính theo loại đặc trưng đầu vào được sử dụng.

2.2.1 Phương pháp dựa trên đặc trưng ảnh RGB

Phần lớn các công trình đạt kết quả tốt nhất hiện nay khai thác trực tiếp thông tin ảnh từ khung hình video. CorrNet [3] đề xuất khai thác tương quan giữa các kênh đặc trưng nhằm học thông tin chuyển động cục bộ, đạt WER 18,8% trên Phoenix-2014. C2SLR [4] kết hợp đặc trưng toàn cục và cục bộ thông qua cơ chế ràng buộc tương quan, đạt WER 20,5%. VAC [5] sử dụng nhánh phụ trợ (Visual Alignment Constraint) để giám sát sự căn chỉnh giữa đặc trưng thị giác và chuỗi gloss ngay trong quá trình huấn luyện.

Ưu điểm: Khai thác tối đa thông tin thị giác phong phú từ ảnh, cho phép đạt WER thấp trên các bộ dữ liệu chuẩn. **Nhược điểm:** Backbone CNN hoặc Transformer xử lý ảnh thường có hàng triệu đến hàng trăm triệu tham số, đòi hỏi GPU chuyên dụng và không phù hợp cho triển khai trên thiết bị tài nguyên hạn chế.

2.2.2 Phương pháp dựa trên đặc trưng keypoint/skeleton

Hướng tiếp cận này sử dụng tọa độ keypoint trích xuất từ mô hình ước lượng tư thế (pose estimation) thay vì ảnh thô, giúp giảm đáng kể chiều dữ liệu đầu vào. SMKD [6] khai thác thông tin khung xương (skeleton) kết hợp chất lọc kiến thức (knowledge distillation) để cải thiện biểu diễn ký hiệu. TwoStream-SLR [7] kết hợp luồng ảnh và luồng skeleton song song, tận dụng bổ sung thông tin từ cả hai nguồn.

Ưu điểm: Dữ liệu keypoint có chiều thấp hơn nhiều so với ảnh, tiết kiệm bộ nhớ và tính toán; bất biến với màu sắc, ánh sáng và nền. **Nhược điểm:** Mất thông tin kết cấu và màu sắc từ ảnh gốc; kết quả phụ thuộc vào chất lượng mô hình ước lượng keypoint phía trước (upstream pose estimator).

2.2.3 Phương pháp kết hợp đa phương thức

Một số công trình gần đây tích hợp nhiều nguồn thông tin bổ sung nhau. BEST [8] kết hợp đặc trưng thị giác toàn cục với đặc trưng tư thế cục bộ thông qua cơ chế cross-attention. NLA-SLR [9] sử dụng neo ngôn ngữ (language anchor) để căn chỉnh biểu diễn thị giác với không gian nhúng gloss.

Ưu điểm: Tận dụng tính bổ sung giữa các phương thức, thường cải thiện WER đáng kể. **Nhược điểm:** Kiến trúc phức tạp, chi phí huấn luyện và suy luận cao; khó triển khai thực tế trên thiết bị biên.

2.2.4 Tổng hợp so sánh các hướng tiếp cận

Bảng 2.1 tổng hợp ưu, nhược điểm của ba nhóm phương pháp được khảo sát, làm căn cứ cho các lựa chọn thiết kế của đề án.

Bảng 2.1: So sánh tổng hợp các hướng tiếp cận CSLR.

Nhóm	Ưu điểm	Nhược điểm	WER tiêu biểu
RGB-based	Thông tin thị giác phong phú; độ chính xác cao	Tham số lớn (30–110M); cần GPU server; không phù hợp thiết bị biên	18–24%
Keypoint-only	Nhẹ, chi phí thấp; bất biến với nền/ánh sáng	Mất thông tin kết cấu; phụ thuộc chất lượng pose estimator	27–35%
Multimodal	Kết hợp bổ sung từ nhiều nguồn; WER thấp	Kiến trúc phức tạp; huấn luyện tốn kém; khó deploy	17–22%
Đề xuất	Nhẹ (1,89M); 5 luồng giải phẫu; Gated Fusion động	Mất thông tin 3D; chưa thử đa dataset	35,39%

2.2.5 Động lực của đề án


Phân tích các hướng tiếp cận trên cho thấy: các phương pháp dựa trên ảnh RGB đạt WER thấp nhất nhưng chi phí mô hình quá lớn; các phương pháp skeleton hiện có chưa khai thác triệt để cấu trúc giải phẫu phân vùng của bàn tay, miệng và mặt – những thành phần mang thông tin ngữ nghĩa cao nhất trong ký hiệu. Đề án này do đó đề xuất một kiến trúc đa luồng giải phẫu thuần keypoint, trong đó mỗi vùng cơ thể được mã hóa độc lập và hợp nhất qua cơ chế gating động, nhằm đạt cân bằng tốt hơn giữa độ chính xác và chi phí tính toán.

2.3 Mô hình mạng nơ-ron cho chuỗi thời gian

2.3.1 Mạng tích chập giãn nở (Dilated TCN)

Mạng tích chập thời gian (Temporal Convolutional Network – TCN) [10] là kiến trúc sử dụng tích chập nhân quả (causal convolution) kết hợp kỹ thuật giãn nở (dilation) để mở rộng trường tiếp nhận (receptive field) mà không tăng số tham số. Với hệ số giãn nở d , một lớp tích chập kernel k bao phủ đoạn thời gian có độ dài hiệu dụng $(k - 1) \times d + 1$ khung hình. Tham khảo hình 2.3.

Trong đề án, TCN sử dụng kiến trúc WaveNet với bốn mức dilation liên tiếp $d \in \{1, 2, 4, 8\}$, cho trường tiếp nhận 31 khung hình (tương đương $\approx 1,2$ giây ở 25fps). Mỗi khối TCN gồm hai lớp Depthwise-Separable Convolution (giảm tham



Hình 2.3: Mô phỏng kiến trúc của mạng Dilated TCN

số), Batch Normalization và kết nối tắt (residual connection):


$$\mathbf{h}_t = \text{ReLU}(\text{BN}(\text{DWConv}_d(\mathbf{x}_t))) + \mathbf{x}_t \quad (2.1)$$

So với LSTM hay GRU, TCN có ưu điểm là có thể huấn luyện song song trên toàn chuỗi (không phụ thuộc bước thời gian trước), giúp tăng tốc đáng kể quá trình huấn luyện.

2.3.2 Tích chập phân tách theo chiều sâu (Depthwise-Separable Convolution)

Trong đề án sử dụng **Depthwise-Separable Convolution** (DSConv) thay cho tích chập 1D tiêu chuẩn trong mỗi tầng TCN, nhằm giảm số tham số mà không làm suy giảm đáng kể chất lượng đặc trưng. DSConv phân tách phép tích chập thành

hai bước nối tiếp, mỗi bước chỉ xử lý một khía cạnh của thông tin. Tham khảo hình 2.4



Hình 2.4: Mạng Dilated TCN đồ án sử dụng

Bước 1 – Depthwise Convolution. Mỗi kênh đầu vào được xử lý độc lập bởi một kernel riêng, không trộn thông tin giữa các kênh. Cho chuỗi đầu vào $x \in \mathbb{R}^{T \times C}$ và hệ số giãn nở d , phép biến đổi được tính theo:

$$\hat{x}_{t,c} = \sum_{i=-\lfloor k/2 \rfloor}^{\lfloor k/2 \rfloor} w_i^{(c)} \cdot x_{t \cdot d + i, c} \quad (2.2)$$

với $w^{(c)} \in \mathbb{R}^k$ là kernel riêng của kênh c . Bước này nắm bắt phụ thuộc thời gian trên từng kênh với số tham số chỉ là $k \times C$.

Bước 2 – Pointwise Convolution. Tích chập 1×1 kết hợp thông tin giữa các kênh để học biểu diễn chéo kênh:


$$y_{t,j} = \sum_{c=1}^C v_{c,j} \cdot \hat{x}_{t,c} \quad (2.3)$$

với ma trận trọng số $v \in \mathbb{R}^{C \times C_{\text{out}}}$ và số tham số $C \times C_{\text{out}}$.

Tổng số tham số của DSConv là $k \times C + C \times C_{\text{out}}$, so với $k \times C \times C_{\text{out}}$ của tích chập tiêu chuẩn. Tỷ lệ tiết kiệm tham số là:

$$\rho = \frac{k \times C + C \times C_{\text{out}}}{k \times C \times C_{\text{out}}} = \frac{1}{C_{\text{out}}} + \frac{1}{k} \quad (2.4)$$

Với $k = 3$ và $C = C_{\text{out}} = 128$ trong đồ án, $\rho \approx 34\%$, tức DSConv chỉ dùng khoảng 1/3 số tham số so với tích chập thông thường tại cùng cấu hình kernel và số kênh. Kết hợp với kỹ thuật giãn nở $d \in \{1, 2, 4, 8\}$, DSConv cho phép xây dựng khối TCN với trường tiếp nhận 31 khung hình ($\approx 1,2$ giây) mà tổng số tham số của 5 luồng $\times$ 4 tầng vẫn dưới 300K – yếu tố then chốt để toàn bộ mô hình huấn luyện được trên GPU 2 GB VRAM. Hình 2.5 minh họa trực quan sự khác biệt giữa hai phép tích chập.



Hình 2.5: So sánh Tích chập 1D tiêu chuẩn (a) và Depthwise-Separable Convolution (b).

2.3.3 Mạng hồi tiếp hai chiều (BiGRU)

Gated Recurrent Unit (GRU) [11] là biến thể đơn giản hóa của LSTM, sử dụng hai cổng (cổng cập nhật z_t và cổng đặt lại r_t) để kiểm soát luồng thông tin qua thời gian:

$$z_t = \sigma(W_z[h_{t-1}, x_t]) \quad (2.5)$$

$$r_t = \sigma(W_r[h_{t-1}, x_t]) \quad (2.6)$$

$$\tilde{h}_t = \tanh(W_h[r_t \odot h_{t-1}, x_t]) \quad (2.7)$$


$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (2.8)$$

GRU hai chiều (BiGRU) chạy đồng thời một GRU xuôi chiều và một GRU

ngược chiều, sau đó nối (concatenate) hai trạng thái ẩn lại:

$$h_t = [\vec{h}_t \parallel \overleftarrow{h}_t] \quad (2.9)$$

BiGRU mã hóa ngữ cảnh cả quá khứ và tương lai tại mỗi bước thời gian, đặc biệt hữu ích trong bài toán nhận dạng chuỗi nơi ngữ nghĩa của một ký hiệu phụ thuộc vào các ký hiệu liền kề. Hình 2.6 minh họa kiến trúc BiGRU tổng quát gồm bốn thành phần nối tiếp: tầng Embedding chiếu đầu vào vào không gian đặc trưng, hai luồng GRU xuôi và ngược chiều chạy song song qua T bước thời gian, bước Concatenate hợp nhất đầu ra hai luồng, và các tầng Dense tạo ra dự đoán cuối cùng.



Hình 2.6: Kiến trúc mạng BiGRU tổng quát. Đầu vào được ánh xạ qua tầng Embedding trước khi đưa vào hai luồng GRU song song: Forward GRU ($\overrightarrow{GRU}$) xử lý chuỗi từ trái sang phải và Backward GRU ($\overleftarrow{GRU}$) xử lý từ phải sang trái qua T bước thời gian. Đầu ra của hai luồng tại mỗi bước được nối (Concatenate) thành vector đặc trưng kết hợp mang ngữ cảnh cả hai chiều, sau đó qua các tầng Dense để tạo ra đầu ra cuối cùng.

So với LSTM, GRU loại bỏ cổng đầu ra (output gate) và gộp trạng thái ô nhớ

(c_t) với trạng thái ẩn (h_t) thành một trạng thái duy nhất, giảm số lượng tham số xuống còn khoảng $\frac{3}{4}$ so với LSTM cùng kích thước ẩn, trong khi hiệu suất trên nhiều bài toán chuỗi thời gian không giảm đáng kể [11]. Trong bài toán CSLR với độ dài chuỗi trung bình $T \approx 85$ khung hình trên Phoenix-2014T, GRU đủ năng lực mã hóa phụ thuộc tầm trung cần thiết mà không gây quá tải bộ nhớ khi huấn luyện theo batch trên GPU dung lượng hạn chế.

2.3.4 Chuẩn hóa lớp và kết nối tắt

Hai kỹ thuật bổ trợ được sử dụng xuyên suốt mô hình đề xuất là **Layer Normalization** (LN) và **kết nối tắt** (residual connection). Mặc dù đơn giản về mặt triển khai, cả hai đều có đóng góp trong việc ổn định và đẩy nhanh hội tụ của mạng nhiều tầng.

Layer Normalization. Khác với Batch Normalization (BN) chuẩn hóa trên chiều batch, Layer Normalization chuẩn hóa trên chiều đặc trưng tại mỗi bước thời gian độc lập:

$$\text{LN}(\mathbf{x}_t) = \frac{\mathbf{x}_t - \mu_t}{\sqrt{\sigma_t^2 + \epsilon}} \cdot \gamma + \beta \quad (2.10)$$

trong đó $\mu_t = \frac{1}{d} \sum_i x_{t,i}$ và σ_t là trung bình và độ lệch chuẩn tính trên d chiều đặc trưng tại bước t ; $\gamma, \beta \in \mathbb{R}^d$ là tham số học được. Ưu điểm chính của LN là hoàn toàn không phụ thuộc vào batch size, hoạt động ổn định với batch nhỏ và chuỗi có độ dài thay đổi (đặc điểm phổ biến trong bài toán CSLR nơi độ dài video dao động từ vài chục đến hàng trăm khung hình).

Kết nối tắt (Residual Connection). Kết nối tắt cộng trực tiếp đầu vào vào đầu ra của một khối biến đổi:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}; \theta) + \mathbf{x} \quad (2.11)$$

trong đó $\mathcal{F}$ là phép biến đổi của khối (TCN, MLP, ...). Cộng tắt này tạo ra đường dẫn gradient ngắn từ đầu ra về đầu vào, giảm hiện tượng tiêu biến gradient (vanishing gradient) khi huấn luyện mạng có nhiều tầng nối tiếp. Trong đồ án, kết nối tắt (Residual Connection) được áp dụng trong mỗi khối TCN giãn nở và trong BiGRU tinh chỉnh hai lớp, cho phép huấn luyện ổn định mặc dù có tới 5 nhánh mã hóa song song cùng tham gia lan truyền ngược (Backpropagation).

Sự kết hợp Layer Normalization + kết nối tắt (Residual Connection) + Dropout tạo thành cấu trúc module hóa được tái sử dụng trong toàn bộ mô hình, đảm bảo gradient không bị suy giảm qua nhiều lớp và mô hình có thể học ổn định từ bước đầu huấn luyện.

2.4 Hàm mất mát CTC và nhận dạng chuỗi không phân đoạn

2.4.1 Bài toán căn chỉnh chuỗi

Trong CSLR, chuỗi khung hình $\mathbf{x} = (x_1, \dots, x_T)$ có độ dài T cần được ánh xạ sang chuỗi nhãn $\mathbf{y} = (y_1, \dots, y_N)$ với $N \ll T$, mà không có thông tin về vị trí thời gian của từng ký hiệu. Đây là bài toán căn chỉnh chuỗi không giám sát (unsupervised alignment), không thể giải trực tiếp bằng cross-entropy thông thường.

2.4.2 Connectionist Temporal Classification (CTC)


CTC [12] giải quyết bài toán trên bằng cách giới thiệu ký tự trống (blank token $\emptyset$) và định nghĩa ánh xạ many-to-one $\mathcal{B}$ từ chuỗi căn chỉnh π (độ dài T) sang chuỗi nhãn $\mathbf{y}$ (độ dài N) thông qua hai thao tác: xóa các nhãn lặp liên tiếp và xóa ký tự trống. Xác suất đầu ra của nhãn $\mathbf{y}$ được tính bằng tổng xác suất trên tất cả căn chỉnh hợp lệ:

$$p(\mathbf{y} | \mathbf{x}) = \sum_{\pi \in \mathcal{B}^{-1}(\mathbf{y})} \prod_{t=1}^T p(\pi_t | \mathbf{x}) \quad (2.12)$$

Hàm mất mát CTC cực tiểu hóa log-likelihood âm:

$$\mathcal{L}_{\text{CTC}} = -\ln p(\mathbf{y} | \mathbf{x}) \quad (2.13)$$

Tổng trên tất cả các căn chỉnh hợp lệ được tính hiệu quả bằng giải thuật lập trình động forward-backward, có độ phức tạp $O(T \times N)$. Hình 2.7 minh họa một đường căn chỉnh hợp lệ điển hình.



Hình 2.7: Ví dụ minh họa CTC: chuỗi đầu vào $T=9$ khung hình được căn chỉnh với chuỗi nhãn mở rộng " $\emptyset A \emptyset B \emptyset$ " (xen blank giữa các gloss). Đường tô đậm cho thấy một căn chỉnh hợp lệ ($\emptyset, A, A, A, \emptyset, B, B, B, \emptyset$) – sau khi xóa nhãn lặp và blank cho kết quả "AB". CTC tổng hợp xác suất trên *tất cả* đường hợp lệ nên không yêu cầu chọn trước một căn chỉnh cụ thể.

2.4.3 Giải mã tham lam (Greedy Decoding)

Trong giai đoạn suy luận, chuỗi gloss được giải mã bằng phương pháp tham lam: tại mỗi bước t , chọn nhãn có xác suất cao nhất $\hat{\pi}_t = \arg \max_c p(c \mid x_t)$, sau đó áp dụng ánh xạ $\mathcal{B}$ để thu được chuỗi gloss cuối cùng. Phương pháp này có độ phức tạp $O(T \times |\mathcal{G}|)$ và phù hợp cho ứng dụng thời gian thực.

2.4.4 Ưu điểm của CTC so với các phương pháp căn chỉnh khác

Trước khi CTC ra đời, các phương pháp nhận dạng chuỗi thường yêu cầu thông tin căn chỉnh (alignment) giữa đầu vào và đầu ra được cung cấp sẵn trong dữ liệu huấn luyện, điều này tốn kém về mặt gán nhãn thủ công. Một hướng khác là sử dụng Hidden Markov Model (HMM) kết hợp mô hình phát xạ, nhưng HMM đặt ra các giả định Markov cứng nhắc và yêu cầu xây dựng đồ thị từ phức tạp. CTC khắc phục cả hai hạn chế trên bằng cách: (1) cho phép mô hình tự học căn chỉnh từ cặp dữ liệu (chuỗi đầu vào, chuỗi nhãn) mà không cần nhãn vị trí; (2) không đặt giả định Markov, mọi căn chỉnh hợp lệ đều được tính vào xác suất đầu ra. Nhờ đó, CTC đặc biệt phù hợp với bài toán CSLR nơi ranh giới gloss không xác định và thời lượng mỗi ký hiệu biến đổi liên tục giữa các người ký.

So sánh giải mã tham lam và beam search. Ngoài giải mã tham lam, CTC còn hỗ trợ giải mã beam search: tại mỗi bước thời gian, thay vì chọn một nhãn có xác suất cao nhất, beam search duy trì B chuỗi ứng cử (beam) có xác suất tích lũy cao nhất. Kết quả cuối cùng là chuỗi có log-likelihood cao nhất trong B beam. Beam search có thể tích hợp thêm mô hình ngôn ngữ gloss ngoại vi (LM rescoring) để cải thiện WER thêm 1–3 điểm phần trăm so với greedy. Tuy nhiên, beam search có độ phức tạp $O(T \times B \times |\mathcal{G}|)$ với B thường từ 5 đến 20 và yêu cầu mô hình ngôn ngữ được huấn luyện riêng trên chuỗi gloss. Trong đồ án này, greedy decoding được chọn vì: (a) mục tiêu hướng tới triển khai thời gian thực trên thiết bị tài nguyên hạn chế; (b) cải thiện từ beam search không đủ bù đắp chi phí tính toán và độ phức tạp triển khai thêm; và (c) các baseline được so sánh trong bảng kết quả cũng phần lớn dùng greedy hoặc beam search nhỏ ($B \leq 10$), đảm bảo tính công bằng khi so sánh.

Bảng 2.2 tóm tắt so sánh ba phương pháp nhận dạng chuỗi phổ biến trong bài toán CSLR:

Tóm tắt chương. Chương này đã trình bày ngữ cảnh và thách thức của bài toán CSLR, giới thiệu mô hình ước lượng tư thế HRNet làm nền tảng tiền xử lý, phân tích ưu nhược điểm của ba nhóm phương pháp hiện có và làm rõ khoảng trống nghiên cứu mà đồ án hướng đến. Ba nền tảng kỹ thuật cốt lõi: mô hình trích xuất tư thế (HRNet), mạng nơ-ron thời gian (TCN, BiGRU) và hàm mất mát CTC đã được

Bảng 2.2: So sánh các phương pháp nhận dạng chuỗi cho bài toán CSLR.

Phương pháp	Yêu cầu nhãn	Ưu điểm	Nhược điểm
HMM + GMM	Nhãn phân đoạn thời gian	Giải thích được; lâu đời	Giả định Markov; xây dựng từ vựng phức tạp
CTC (greedy)	Chỉ cần nhãn chuỗi	Không cần căn chỉnh; $O(T)$ suy luận	Giả định độc lập điều kiện theo bước thời gian
CTC + Beam + LM	Chỉ cần nhãn chuỗi + corpus gloss	WER tốt hơn 1–3%	$O(T \times B \times \mathcal{G})$; cần LM riêng

trình bày để cung cấp cơ sở lý thuyết cho kiến trúc đề xuất ở Chương 3.


CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Phương pháp đề xuất

3.1.1 Tổng quan kiến trúc

Kiến trúc tổng thể của mô hình đề xuất được minh họa ở Hình 3.1. Hệ thống nhận vào tensor keypoint $X \in \mathbb{R}^{B \times T \times 77 \times 3}$, trong đó B là kích thước batch, T là độ dài chuỗi, 77 là số keypoint chuẩn hóa trên mỗi khung hình, và 3 là (x, y, c) với c là độ tin cậy của bộ ước lượng pose. Pipeline gồm bốn giai đoạn chính:

1. **Tách năm luồng:** chuỗi keypoint được chia theo các slice cố định thành pose (9 điểm), tay trái (21), tay phải (21), miệng (12) và khuôn mặt (14).
2. **Bộ mã hóa từng luồng:** mỗi luồng được đưa qua một mạng Linear $\rightarrow$ LayerNorm $\rightarrow$ Dilated TCN $\rightarrow$ BiGRU độc lập, cho ra đặc trưng $h^{(s)} \in \mathbb{R}^{B \times T \times 128}$.
3. **Hợp nhất theo cổng (Gated Fusion):** năm vector đặc trưng được kết hợp qua trọng số α_t phụ thuộc thời gian, sinh ra đặc trưng hợp nhất $f \in \mathbb{R}^{B \times T \times 128}$.
4. **Tinh chỉnh thời gian và đầu CTC:** một BiGRU hai lớp tinh chỉnh ngữ cảnh toàn câu, sau đó lớp tuyến tính chiếu lên không gian 1124 lớp và áp dụng log-softmax để dùng cho CTC loss.



Hình 3.1: Sơ đồ tổng quan của mô hình đề xuất. Năm luồng giải phẫu được mã hóa độc lập, hợp nhất qua cổng phụ thuộc thời gian, tinh chỉnh thời gian và phân lớp bằng CTC.

3.1.2 Tiền xử lý và biểu diễn keypoint

Mỗi khung hình của video gốc được trích xuất 77 keypoint chuẩn hóa, sắp xếp theo thứ tự cố định pose $\rightarrow$ tay trái $\rightarrow$ tay phải $\rightarrow$ miệng $\rightarrow$ khuôn mặt (Bảng 3.1). Việc đặt thứ tự cố định cho phép tách năm luồng chỉ bằng các slice tensor, loại bỏ

chi phí gather động.

Bảng 3.1: Phân bố 77 keypoint theo năm luồng giải phẫu.

Luồng	Slice	Số điểm	Vai trò ngữ nghĩa
Pose (thân)	[0 : 9]	9	Ngữ cảnh không gian, vai/đầu
Tay trái	[9 : 30]	21	Modality chính #1
Tay phải	[30 : 51]	21	Modality chính #2
Miệng	[51 : 63]	12	Mouthing, phân biệt cử chỉ đồng dạng
Khuôn mặt	[63 : 77]	14	Biểu cảm/ngữ pháp
Tổng		77	

Đặc trưng vận tốc. Bên cạnh tọa độ (x, y, c) thô, chúng tôi bổ sung đặc trưng vận tốc $(\Delta x, \Delta y)$ tính bằng sai phân hữu hạn giữa hai khung hình liên tiếp.

Tăng cường dữ liệu. Để tăng tính bất biến của mô hình với nhiễu thực tế trong quá trình trích xuất pose và sự đa dạng phong cách ký hiệu giữa các người ký, bốn phép biến đổi xác suất được áp dụng độc lập và có thể kết hợp đồng thời trong huấn luyện:

1. **Lấy mẫu lại theo thời gian** (xác suất kích hoạt 0,5): chuỗi keypoint được co giãn theo trục thời gian với tỉ lệ ngẫu nhiên $r \in [0,7; 1,3]$ bằng nội suy tuyến tính, mô phỏng sự khác biệt tốc độ ký giữa các cá nhân.
2. **Nhiều Gaussian** (xác suất 0,5): cộng nhiễu $\epsilon \sim \mathcal{N}(0, 0,005^2)$ vào tọa độ (x, y) của mỗi keypoint, mô phỏng sai số đầu ra của bộ ước lượng pose.
3. **Xoay 2D ngẫu nhiên** (xác suất 0,3): xoay toàn bộ chuỗi keypoint một góc $\theta \in [-0,15; 0,15]$ radian quanh tâm bounding box, tăng tính bất biến với góc nghiêng đầu và cơ thể.
4. **Keypoint dropout** (xác suất kích hoạt 0,2): đặt về 0 một số điểm keypoint ngẫu nhiên với tỉ lệ $p_{\text{drop}} = 0,05$ trên mỗi khung hình, mô phỏng trường hợp bộ ước lượng pose không phát hiện được một số khớp do bị che khuất.

3.1.3 Luận chứng lựa chọn phân vùng năm luồng giải phẫu

Quyết định chia 77 keypoint thành đúng năm luồng – thay vì xử lý như một vector phẳng hay dùng số luồng khác – dựa trên ba luận điểm kết hợp: đặc điểm sinh lý của ngôn ngữ ký hiệu, phân phối thông tin ngữ nghĩa giữa các vùng cơ thể, và tính độc lập tương đối của chuyển động.

Đặc điểm sinh lý của ngôn ngữ ký hiệu. Ngôn ngữ học ký hiệu (sign linguistics) xác định bốn thông số cấu thành (phonological parameters) của mỗi ký hiệu [13]:

(a) *hình dạng bàn tay* (handshape) – mã hóa bởi luồng tay trái và tay phải; (b) *vị trí* (location) trong không gian ký hiệu – thể hiện qua luồng thân (pose); (c) *hướng lòng bàn tay* (palm orientation) – cũng trong luồng tay; và (d) *chuyển động* (movement) – phân bố trên tất cả luồng qua đặc trưng vận tốc $(\Delta x, \Delta y)$. Ngoài ra, *mouthing* (khẩu hình tiếng nói đồng thời với ký hiệu) là tín hiệu phụ trợ quan trọng để phân biệt các gloss đồng dạng – được mã hóa bởi luồng miệng. Phân vùng năm luồng do đó tương ứng tự nhiên với năm loại thông tin sinh lý của ký hiệu.

Phân phối thông tin ngữ nghĩa. Các luồng không đóng góp như nhau vào việc phân biệt ký hiệu. Tay trái và tay phải mang hầu hết thông tin phân biệt (discriminative information) vì đây là các bộ phận thực hiện chuyển động chính; miệng giúp giảm nhập nhằng cho các ký hiệu có hình dạng tay tương tự; trong khi khuôn mặt và thân chủ yếu cung cấp ngữ cảnh không gian và nhãn ngữ pháp (nonmanual markers trong DGS). Trọng số aux CTC ($\lambda_{LH} = \lambda_{RH} = 0,3 > \lambda_{mouth} = 0,2 > \lambda_{face} = \lambda_{pose} = 0$) phản ánh trực tiếp thứ bậc này: tay được giám sát mạnh nhất, miệng giám sát mức vừa, còn mặt và thân chỉ đóng góp qua Gated Fusion mà không có nhánh aux riêng.

Tính độc lập tương đối. Chuyển động tay phải có thể độc lập hoàn toàn với chuyển động miệng hoặc biểu cảm khuôn mặt trong cùng một khung hình. Nếu xử lý 77 keypoint như một vector phẳng duy nhất, mô hình phải tự học cách tách biệt các tín hiệu này từ không gian hỗn hợp – bài toán khó hơn và kém hiệu quả về tham số. Mã hóa riêng từng vùng rồi hợp nhất có điều khiển (Gated Fusion) đơn giản hóa không gian đầu vào của mỗi bộ mã hóa, giúp từng StreamEncoder tập trung vào đặc trưng đặc thù của vùng mà không bị nhiễu bởi chuyển động của vùng khác.

Bảng 3.2 tóm tắt vai trò ngữ nghĩa và thiết kế giám sát của năm luồng:

Bảng 3.2: Vai trò ngữ nghĩa và cấu hình giám sát của năm luồng giải phẫu.

Luồng	Thông số ký hiệu	#Keypoint	λ_{aux}	Vai trò chính
Tay phải	Handshape, Movement, Orientation	21	0,3	Modality ngữ nghĩa chính #1
Tay trái	Handshape, Movement, Orientation	21	0,3	Modality ngữ nghĩa chính #2
Miệng	Mouthing	12	0,2	Giảm nhập nhằng gloss đồng dạng
Khuôn mặt	Nonmanual markers	14	–	Ngữ pháp, biểu cảm
Thân	Location, ngữ cảnh không gian	9	–	Vị trí thực hiện ký hiệu

3.1.4 Bộ mã hóa từng luồng

Mỗi luồng đi qua một module *StreamEncoder* gồm ba khối nối tiếp.

(1) Chiều tuyến tính. Đặc trưng $[B, T, J, 5]$ của luồng (với J là số keypoint của luồng) được làm phẳng theo chiều khớp thành $[B, T, 5 * J]$ rồi chiếu tuyến tính lên

không gian embedding $d = 128$ chiều:

$$z_t = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{x}_t W + b))), \quad (3.1)$$

trong đó $\mathbf{x}_t \in \mathbb{R}^{5J}$ là vector đặc trưng đầu vào của luồng tại khung hình t , thu được bằng cách làm phẳng J keypoint của luồng đó với 5 kênh mỗi keypoint $(x, y, c, \Delta x, \Delta y)$ (tọa độ chuẩn hóa, độ tin cậy của bộ ước lượng pose, và vận tốc theo hai trục); $W \in \mathbb{R}^{128 \times 5J}$ là ma trận trọng số học được của phép chiếu tuyến tính từ không gian đầu vào $5J$ chiều lên không gian embedding 128 chiều; và $b \in \mathbb{R}^{128}$ là vector bias học được. Đầu ra $W\mathbf{x}_t + b$ tiếp đó được đi qua LayerNorm để chuẩn hóa thống kê, hàm kích hoạt GELU và Dropout, cho ra biểu diễn $z_t \in \mathbb{R}^{128}$ của luồng tại khung hình t .

(2) Mạng tích chập thời gian giãn nở. Mục tiêu là học các mẫu chuyển động ngắn–đến–trung trên trục thời gian. Khối TCN gồm bốn tầng depthwise–separable Conv1d với dilation $\{1, 2, 4, 8\}$, kernel size 3, BatchNorm và kích hoạt GELU:

$$h^{\text{tcn}} = \text{GELU}(\text{TCN}(z) + z) W_{\text{skip}}. \quad (3.2)$$

trong đó $z \in \mathbb{R}^{B \times T \times 128}$ là đầu ra của bước chiếu tuyến tính ở phần (1); $\text{TCN}(\cdot)$ ký hiệu phép biến đổi tổng hợp của bốn tầng depthwise–separable Conv1d giãn nở trên; và W_{skip} là ma trận trọng số học được của một lớp tích chập điểm (1×1 Conv) trên nhánh tắt (skip connection). W_{skip} có vai trò vừa khớp số kênh giữa đầu vào và đầu ra của khối TCN khi cần, vừa cung cấp đường dẫn gradient ngắn giúp ổn định quá trình huấn luyện và tránh hiện tượng tiêu biến gradient ở các tầng sâu.

(3) BiGRU. Sau TCN, chuỗi đặc trưng được đưa qua một lớp GRU hai chiều với 64 đơn vị mỗi chiều, cho ra đầu ra 128 chiều. GRU nhẹ hơn LSTM và phù hợp với chuỗi không quá dài của các video PHOENIX ($T \leq 300$ khung hình).

Đầu ra của mỗi luồng s được ký hiệu $h^{(s)} \in \mathbb{R}^{B \times T \times 128}$.

3.1.5 Hợp nhất theo cổng phụ thuộc thời gian

Năm vector đặc trưng được stack thành tensor $H \in \mathbb{R}^{B \times T \times 5 \times 128}$. Tại mỗi khung hình t , một MLP nhẹ tính trọng số đóng góp $\alpha_t \in \mathbb{R}^5$:


$$\tilde{\alpha}_t = W_2 \text{GELU}(W_1 \cdot \text{concat}(H_t)), \quad (3.3)$$

$$\alpha_t = \text{softmax}(\tilde{\alpha}_t), \quad (3.4)$$

trong đó $\text{concat}(H_t) \in \mathbb{R}^{640}$ là vector thu được bằng cách nối tiếp 5 vector đặc trưng 128 chiều của 5 luồng tại khung hình t (do đó có tổng số chiều $5 \times 128 = 640$); $W_1 \in \mathbb{R}^{320 \times 640}$ là ma trận trọng số học được của tầng thứ nhất của một MLP hai tầng, chiếu vector nối từ không gian 640 chiều xuống không gian ẩn 320 chiều; $W_2 \in \mathbb{R}^{5 \times 320}$ là ma trận trọng số học được của tầng thứ hai, chiếu từ 320 chiều xuống 5 chiều logits, mỗi chiều tương ứng với một luồng giải phẫu. Hàm softmax sau đó chuẩn hóa 5 logits thô $\tilde{\alpha}_t$ thành phân phối trọng số đóng góp $\alpha_t \in \mathbb{R}^5$ thỏa $\sum_{s=1}^5 \alpha_{t,s} = 1$ và $\alpha_{t,s} \geq 0$. Đặc trưng hợp nhất sau đó là tổng có trọng số:

$$f_t = \text{LN} \left(\sum_{s=1}^5 \alpha_{t,s} \cdot h_t^{(s)} \right). \quad (3.5)$$

Việc tính α_t theo từng khung hình cho phép mô hình tăng đóng góp của left/right_hand ở các khung có cử chỉ tay rõ rệt, và tăng đóng góp của mouth/face khi mouthing hoặc biểu cảm ngữ pháp xuất hiện. Hình 3.2 minh họa luồng dữ liệu của cơ chế Gated Fusion.



Hình 3.2: Sơ đồ cơ chế Gated Fusion phụ thuộc thời gian. Năm vector đặc trưng luồng (128-d mỗi luồng) được nối thành vector 640-d, đưa qua MLP (640 $\rightarrow$ 320 $\rightarrow$ 5) và softmax để học trọng số đóng góp α_t tại từng khung hình t . Đặc trưng hợp nhất f_t là tổng có trọng số qua Layer Normalization.

3.1.6 Tinh chỉnh thời gian và đầu CTC

Đặc trưng hợp nhất f được tinh chỉnh bằng một BiGRU hai lớp với hidden size 128 (đầu ra 256 chiều), nhằm học các phụ thuộc dài hơn vùng tiếp nhận của TCN, ví dụ thứ tự trước-sau giữa các sign và biên giới gloss. Lớp tuyến tính cuối cùng chiếu đặc trưng tinh chỉnh lên số lớp $C = 1124$ (gồm token blank và bộ từ vựng gloss của bộ dữ liệu Phoenix-2014T), kết quả được đưa qua log-softmax để tạo $\log p_{\theta}(y_t | X) \in \mathbb{R}^{B \times T \times C}$.

3.1.7 Hàm mất mát

CTC chính. Vì không có căn chỉnh sẵn giữa khung hình và gloss, chúng tôi sử dụng Connectionist Temporal Classification (CTC) [12]:

$$\mathcal{L}_{\text{ctc}} = -\log \sum_{\pi \in \mathcal{B}^{-1}(y)} \prod_{t=1}^T p_{\theta}(\pi_t | X), \quad (3.6)$$

trong đó $\mathcal{B}$ là phép thu gọn (collapse repeats + remove blank) và y là chuỗi gloss tham chiếu.

Giám sát phụ trợ. Lấy cảm hứng từ VAC [5] và SMKD [14], chúng tôi bổ sung các nhánh giám sát phụ trợ *chia sẻ trọng số phân lớp* với nhánh chính. Cụ thể:

- **Visual aux:** đặc trưng sau hợp nhất f được chiếu qua một module Linear $\rightarrow$ LN về cùng chiều 256 rồi đưa thẳng vào đầu CTC dùng chung. Hàm mất mát tương ứng $\mathcal{L}_{\text{visual}}$ ép biểu diễn thị giác và biểu diễn chuỗi nằm trên cùng không gian ngữ nghĩa.
- **Per-stream aux:** đặc trưng từ ba luồng quan trọng nhất (tay trái, tay phải, miệng) được chiếu lên 256 chiều và đưa vào đầu CTC dùng chung, sinh ra ba hàm mất mát phụ $\mathcal{L}_{\text{LH}}, \mathcal{L}_{\text{RH}}, \mathcal{L}_{\text{mouth}}$. Việc dùng chung classifier ép từng bộ mã hóa tự học được phân phối gloss trên từng modality, hoạt động như một dạng deep supervision.

Hàm mất mát tổng:

$$\mathcal{L} = \mathcal{L}_{\text{ctc}} + \lambda_v \mathcal{L}_{\text{visual}} + \lambda_{\text{LH}} \mathcal{L}_{\text{LH}} + \lambda_{\text{RH}} \mathcal{L}_{\text{RH}} + \lambda_m \mathcal{L}_{\text{mouth}}, \quad (3.7)$$

với trọng số $\lambda_v = 1,0$, $\lambda_{\text{LH}} = \lambda_{\text{RH}} = 0,3$, $\lambda_m = 0,2$. Lựa chọn λ ưu tiên tay so với miệng phản ánh thứ tự đóng góp ngữ nghĩa của các modality.

3.1.8 Giải mã suy luận

Tại pha suy luận, chúng tôi dùng giải mã CTC tham lam: argmax theo từng khung hình, sau đó thu gọn các token liên tiếp trùng nhau và loại bỏ token blank. Phương pháp này không cần mô hình ngôn ngữ ngoại vi và có độ phức tạp $O(T)$, phù hợp với triển khai thời gian thực.

3.1.9 Tổng kết các lựa chọn thiết kế và so sánh với phương án thay thế

Phần này tổng hợp các lựa chọn kiến trúc chính của đề án và lý do chọn so với các phương án thay thế phổ biến, nhằm làm rõ tính cần thiết của từng thành phần qua góc nhìn thiết kế (design rationale).

Bảng 3.3: Tổng hợp lựa chọn thiết kế và phương án thay thế được cân nhắc.

Thành phần	Lựa chọn	Phương án thay thế	Lý do lựa chọn
Đầu vào	77 keypoint (5 luồng)	ảnh RGB	Nhẹ hơn $\sim 700\times$; không cần CNN
Phân vùng	5 luồng giải phẫu	1 luồng phẳng	Giảm không gian mỗi encoder; phù hợp sinh lý ký hiệu
Trích đặc trưng thời gian	Dilated TCN ($d=[1, 2, 4, 8]$)	RNN thuần / Transformer	Song song hóa tốt; trường tiếp nhận 31 frame
Tích chập	Depthwise-Separable	Tích chập tiêu chuẩn	Giảm $\sim 67\%$ tham số cùng kernel
Hợp nhất	Gated Fusion (attention)	Concatenation + Linear	Học trọng số động; không cố định đóng góp luồng
Tinh chỉnh	BiGRU 2 lớp	Transformer nhỏ / BiLSTM	Nhẹ hơn 25% so với BiLSTM; phù hợp chuỗi $T \leq 300$
Hàm mất mát	CTC đa nhánh	Cross-entropy + căn chỉnh	Không cần nhân vị trí; phù hợp CSLR
Giải mã	Greedy decoding	Beam search + LM	$O(T)$; phù hợp thời gian thực

Kết quả ablation (Bảng 4.9) định lượng tác động thực nghiệm của ba lựa chọn quan trọng nhất: (1) thêm đặc trưng vận tốc giảm WER 5,46 điểm ($A \rightarrow B$); (2) TCN giãn nở $d=[1, 2, 4]$ giảm thêm 2,48 điểm ($B \rightarrow C$); (3) mở rộng dilation lên $d=8$ kết hợp BiGRU 2 lớp giảm thêm 1,02 điểm ($C \rightarrow D$). Những con số này xác nhận mỗi lựa chọn thiết kế đều có đóng góp độc lập và có thể đo lường, không phải quyết định tùy tiện.

3.1.10 Phân tích độ phức tạp tính toán

Bảng 3.4 phân tích số tham số của từng thành phần trong mô hình đề xuất, làm rõ tính gọn nhẹ của kiến trúc và khả năng triển khai trên thiết bị tài nguyên hạn chế.

Bảng 3.4: Phân tích số tham số theo từng thành phần kiến trúc.

Thành phần	Chi tiết	#Params	Tỉ lệ
Per-stream Encoder $\times 5$	Linear($5J \rightarrow 128$) + TCN($d=[1, 2, 4, 8]$) + BiGRU(64)	$\approx 270K$	14,3%
Gated Fusion MLP	Linear($640 \rightarrow 320 \rightarrow 5$)	$\approx 33K$	1,7%
BiGRU Tinh chỉnh (2 lớp)	BiGRU($128 \rightarrow 256$) $\times 2$	$\approx 394K$	20,8%
CTC Head	Linear($256 \rightarrow 1124$) + log-softmax	$\approx 288K$	15,2%
Aux projection heads	Linear($128 \rightarrow 256$) $\times 4$ (VAC, LH, RH, Mouth)	$\approx 903K$	47,8%
Tổng (huấn luyện)		$\approx 1,89M$	100%
Tổng (suy luận)	(bỏ aux heads)	$\approx 985K$	52,2%

Đáng chú ý là các nhánh projection phụ trợ (aux projection heads) chiếm gần 48% tổng tham số nhưng chỉ được sử dụng trong quá trình huấn luyện và không

tham gia vào pha suy luận. Do đó, mô hình triển khai thực tế chỉ cần $\approx 985K$ tham số, tương đương kích thước tải xuống dưới 4 MB ở định dạng float32 – hoàn toàn phù hợp với bộ nhớ của thiết bị di động phổ thông hiện nay.

Tóm tắt chương. Chương này đã trình bày chi tiết toàn bộ kiến trúc mô hình đề xuất, từ bước tiền xử lý keypoint và tăng cường dữ liệu, qua bộ mã hóa đa luồng giải phẫu với Dilated TCN và BiGRU, đến cơ chế Gated Fusion động, BiGRU tinh chỉnh ngữ cảnh câu và đầu phân lớp CTC đa nhánh. Phân tích độ phức tạp cho thấy mô hình suy luận chỉ cần dưới 1M tham số, đáp ứng mục tiêu triển khai trên thiết bị biên đặt ra từ Chương 1. Chương tiếp theo sẽ trình bày kết quả thực nghiệm kiểm chứng hiệu quả của kiến trúc này.

CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM

Chương này trình bày toàn bộ quá trình thực nghiệm và đánh giá mô hình đề xuất. Phần đầu mô tả bộ dữ liệu và thang đo đánh giá được sử dụng. Tiếp theo là chi tiết cài đặt huấn luyện, danh sách các phương pháp được chọn làm baseline so sánh cùng lý do lựa chọn. Phần kết quả thực nghiệm chính so sánh mô hình đề xuất với các phương pháp liên quan, sau đó là nghiên cứu loại bỏ thành phần (ablation study) nhằm định lượng đóng góp của từng khối kiến trúc. Chương kết thúc bằng phân tích và thảo luận về các kết quả đạt được.

4.1 Dữ liệu thực nghiệm

Đồ án thực nghiệm trên hai bộ dữ liệu chuẩn thuộc cùng họ RWTH-PHOENIX-Weather: **Phoenix-2014** và **Phoenix-2014T**. Cả hai đều được thu thập từ cùng nguồn video bản tin thời tiết bằng ngôn ngữ ký hiệu Đức (DGS), song khác nhau về giao thức chú thích và quy mô tập train.

4.1.1 Bộ dữ liệu Phoenix-2014

RWTH-PHOENIX-Weather 2014 [15] là bộ dữ liệu CSLR chuẩn sớm nhất và được trích dẫn rộng rãi nhất trong lĩnh vực, gồm các video bản tin thời tiết DGS do 9 người dẫn chương trình thực hiện trong điều kiện studio. Phiên bản này chỉ chứa chú thích gloss (không có chú thích dịch thuật sang tiếng Đức tự nhiên), do đó được sử dụng đặc thù để đánh giá bài toán CSLR thuần túy.

Bảng 4.1: Thống kê bộ dữ liệu Phoenix-2014.

Tập	Số mẫu	Số token gloss	Độ dài TB (giây)	Số gloss TB/câu
Train	5.672	65.227	3,3	11,5
Dev	540	6.136	3,3	11,4
Test	629	7.245	3,3	11,5
Tổng	6.841	78.608	—	—

Kích thước vốn từ vựng gloss là 1.232 ký hiệu (lớn hơn Phoenix-2014T do giao thức chú thích khác nhau), cộng thêm 1 token trống cho CTC, tổng cộng 1.233 lớp đầu ra.

4.1.2 Bộ dữ liệu Phoenix-2014T

RWTH-PHOENIX-Weather 2014T [13] là phiên bản mở rộng của Phoenix-2014, bổ sung thêm chú thích dịch thuật sang tiếng Đức tự nhiên cho từng câu, phục vụ cả bài toán CSLR lẫn Sign Language Translation (SLT). So với Phoenix-2014, tập train lớn hơn đáng kể (7.094 so với 5.672 mẫu) nhờ việc bổ sung thêm các đoạn

video mới, trong khi vốn từ vựng gloss nhỏ hơn (1.124 ký hiệu) do quy trình chuẩn hóa chú thích chặt chẽ hơn.

Bảng 4.2: Thống kê bộ dữ liệu Phoenix-2014T.

Tập	Số mẫu	Số khung hình	Độ dài TB (giây)	Số gloss TB/câu
Train	7.094	1.066.578	3,4	9,1
Dev	519	76.046	3,3	9,0
Test	642	96.143	3,4	9,2
Tổng	8.255	1.238.767	–	–

Kích thước vốn từ vựng gloss là 1.124 ký hiệu, cộng thêm 1 token trống (blank) cho CTC, tổng cộng 1.125 lớp đầu ra. Video gốc có tốc độ 25fps, độ phân giải 210×260 pixel.

4.1.3 So sánh hai bộ dữ liệu

Bảng 4.3 tóm tắt các điểm khác biệt chính giữa hai bộ dữ liệu.

Bảng 4.3: So sánh Phoenix-2014 và Phoenix-2014T.

Đặc điểm	Phoenix-2014	Phoenix-2014T
Số mẫu train	5.672	7.094
Kích thước từ vựng	1.232	1.124
Chú thích gloss	✓	✓
Chú thích dịch thuật	–	✓
Nguồn video	DGS broadcast, 9 người ký	
Tốc độ khung hình	25 fps, 210×260 px	
Keypoint (HRNet)	77 điểm, tiền xử lý đồng nhất	

Quy trình tiền xử lý keypoint được áp dụng đồng nhất cho cả hai bộ dữ liệu: phân vùng 77 điểm thành 5 luồng giải phẫu, tính đặc trưng vận tốc ($\Delta x, \Delta y$) giữa các khung hình liên tiếp, và áp dụng các kỹ thuật tăng cường dữ liệu giống nhau trong quá trình huấn luyện (Hình 4.1). Điều này cho phép so sánh trực tiếp kết quả trên hai bộ dữ liệu mà không bị ảnh hưởng bởi sự khác biệt tiền xử lý.

4.1.4 Tiền xử lý keypoint

Thay vì xử lý ảnh RGB trực tiếp, đồ án sử dụng bộ keypoint được trích xuất sẵn bởi HRNet [2] và phân phối công khai cùng bộ dữ liệu. Từ 77 điểm keypoint thô, dữ liệu được phân vùng thành năm luồng giải phẫu theo Bảng 4.4. Mỗi điểm keypoint có 2 tọa độ (x, y) đã được chuẩn hóa theo kích thước khung hình; ngoài ra đặc trưng vận tốc ($\Delta x, \Delta y, \|\Delta\|$) giữa hai khung hình liên tiếp được tính và nối thêm, tạo thành 5 kênh đặc trưng trên mỗi khớp.

Bảng 4.4: Phân vùng 77 keypoint thành 5 luồng giải phẫu.

Luồng	Vùng giải phẫu	Số khớp	Chỉ số	Đặc trưng/khung
Tay trái	Ngón tay trái	21	9–29	$21 \times 5 = 105$
Tay phải	Ngón tay phải	21	30–50	$21 \times 5 = 105$
Miệng	Vùng môi, miệng	12	51–62	$12 \times 5 = 60$
Mặt	Đường viền mặt	14	63–76	$14 \times 5 = 70$
Thân	Khớp thân, vai, hông	9	0–8	$9 \times 5 = 45$

4.2 Tham số đánh giá

Thang đo chính được sử dụng là **Word Error Rate (WER)**, tiêu chuẩn phổ biến nhất trong cộng đồng nghiên cứu CSLR và nhận dạng giọng nói:

$$\text{WER} = \frac{S + D + I}{N} \times 100\% \quad (4.1)$$

trong đó S , D , I lần lượt là số gloss bị thay thế (Substitution), bị xóa (Deletion) và bị chèn thêm (Insertion) so với chuỗi tham chiếu; N là tổng số gloss trong tập tham chiếu. WER được tính bằng giải thuật Dynamic Programming (khoảng cách chỉnh sửa Levenshtein). WER thấp hơn đồng nghĩa với hiệu suất nhận dạng tốt hơn; $\text{WER} = 0$ tương ứng nhận dạng hoàn hảo.

Mô hình được đánh giá độc lập trên tập **Dev** và tập **Test**, tương ứng với hai cột “Dev WER” và “Test WER” trong các bảng kết quả. Checkpoint được lưu theo Dev WER thấp nhất trong quá trình huấn luyện.

4.3 Cài đặt thực nghiệm

4.3.1 Môi trường phần cứng và phần mềm

Tất cả thực nghiệm được thực hiện trên một máy tính cá nhân với cấu hình phần cứng và phần mềm như sau. Về phần cứng: CPU Intel Core i5 thế hệ 11, RAM 16 GB, GPU NVIDIA GeForce MX450 với 2 GB VRAM – phân khúc GPU tích hợp dành cho laptop phổ thông, không thuộc dòng chuyên dụng deep learning.

Thời gian huấn luyện $\approx 28\text{--}40$ giờ cho 200 epoch trên GPU 2 GB là chấp nhận được cho một đồ án nghiên cứu. So sánh tương đối: các phương pháp RGB như CorrNet thường yêu cầu 3–5 ngày huấn luyện trên GPU V100 16 GB theo báo cáo trong các bài báo gốc, trong khi mô hình đề xuất có thể huấn luyện hoàn tất trong một cuối tuần trên phần cứng thông thường.

Bảng 4.5: Cấu hình thực nghiệm chi tiết.

Thành phần	Chi tiết
GPU	NVIDIA GeForce MX450 (2 GB VRAM, CUDA 11.8)
Framework	PyTorch [16] 2.0
Ngôn ngữ	Python 3.10
CTC loss	<code>torch.nn.CTCLoss</code> (backend cuDNN)
Thời gian train/epoch	$\approx 8\text{--}12$ phút (tùy độ dài batch)
Tổng thời gian (200 epoch)	$\approx 28\text{--}40$ giờ
Định dạng lưu checkpoint	<code>.pt</code> (state_dict, float32)

4.3.2 Siêu tham số huấn luyện


Lịch học `OneCycleLR` tăng dần learning rate trong 30% đầu số epoch rồi giảm theo cosine annealing, giúp mô hình hội tụ nhanh hơn so với lịch học cố định. Hàm mất mát tổng thể là tổ hợp tuyến tính giữa mất mát CTC chính và các mất mát CTC phụ trợ:

$$\mathcal{L} = \mathcal{L}_{\text{CTC}}^{\text{main}} + 1.0 \mathcal{L}_{\text{CTC}}^{\text{visual}} + 0.3 \mathcal{L}_{\text{CTC}}^{\text{LH}} + 0.3 \mathcal{L}_{\text{CTC}}^{\text{RH}} + 0.2 \mathcal{L}_{\text{CTC}}^{\text{mouth}} \quad (4.2)$$

4.3.3 Tăng cường dữ liệu

Bốn kỹ thuật tăng cường dữ liệu được áp dụng trong quá trình huấn luyện, mô tả chi tiết trong Chương 3: lấy mẫu lại theo thời gian (xác suất 0,5, tỉ lệ $\in [0,7; 1,3]$), nhiễu Gaussian trên (x, y) với $\sigma = 0,005$ (xác suất 0,5), xoay 2D ngẫu nhiên trong $[-0,15; 0,15]$ radian (xác suất 0,3), và keypoint dropout với $p_{\text{drop}} = 0,05$ (xác suất kích hoạt 0,2). Hình 4.1 minh họa trực quan tác động của ba kỹ thuật chính lên keypoint bàn tay. Các phép biến đổi được áp dụng độc lập và có thể kết hợp đồng thời, tạo ra không gian tăng cường đa dạng giúp mô hình tổng quát hóa tốt hơn trên tập kiểm thử.

Hình minh họa bốn kỹ thuật tăng cường dữ liệu trên keypoint bàn tay



Hình 4.1: Minh họa bốn kỹ thuật tăng cường dữ liệu trên keypoint bàn tay: (a) keypoint gốc; (b) temporal resampling – hai frame ở tốc độ khác nhau (xanh đậm: frame gốc, đỏ: frame giãn thời gian); (c) nhiễu Gaussian thêm vào tọa độ (x, y) ; (d) xoay 2D ngẫu nhiên quanh tâm bounding box (xanh mờ: gốc, tím: sau xoay).

Bảng 4.6: Siêu tham số huấn luyện của mô hình đề xuất.

Siêu tham số	Giá trị
Số epoch	200
Batch size	16
Optimizer	AdamW
Learning rate (khởi đầu)	1×10^{-3}
Lịch lr	OneCycleLR (max_lr = 10^{-3})
Weight decay	1×10^{-4}
Gradient clipping	5.0
Dropout	0.3
CTC blank token ID	0
embed_dim (chiều chiều)	128
tcn_channels	128
tcn_kernel	3
tcn_dilations	[1, 2, 4, 8]
gru_hidden (mỗi chiều)	64
refine_hidden	128
refine_layers (BiGRU tinh chỉnh)	2
Trọng số aux visual	1.0
Trọng số aux tay trái	0.3
Trọng số aux tay phải	0.3
Trọng số aux miệng	0.2

4.4 Các phương pháp so sánh

Để đánh giá toàn diện mô hình đề xuất, đồ án chọn các baseline đại diện cho hai nhóm phương pháp chính:

Nhóm 1 – Phương pháp dựa trên đặc trưng ảnh RGB: Nhóm này đại diện cho hiệu suất tốt nhất hiện tại nhưng chi phí tính toán cao.

- **VAC** [5]: sử dụng nhánh Visual Alignment Constraint để căn chỉnh đặc trưng thị giác với chuỗi gloss.
- **C2SLR** [4]: khai thác tương quan giữa đặc trưng toàn cục và cục bộ qua cơ chế ràng buộc tương quan.
- **CorrNet** [3]: học tương quan kênh đặc trưng để nắm bắt thông tin chuyển động cục bộ.

Nhóm 2 – Phương pháp dựa trên keypoint/skeleton: Nhóm này có cùng loại đầu vào với đồ án, cho phép so sánh trực tiếp và công bằng nhất.

- **SMKD** [14]: khai thác skeleton kết hợp chất lọc kiến thức (knowledge distillation)

từ mô hình RGB.

- **TwoStream-SLR (Skel)** [7]: luồng skeleton trong kiến trúc hai luồng RGB + skeleton.

Lý do chọn các baseline trên: (i) VAC, C2SLR và CorrNet thiết lập đường biên hiệu suất của phương pháp RGB để thấy rõ khoảng cách giữa hai nhóm; (ii) SMKD và TwoStream-SLR cho phép so sánh công bằng trong cùng điều kiện đầu vào keypoint, qua đó định lượng lợi ích của kiến trúc đa luồng giải phẫu đề xuất.

4.5 Kết quả thực nghiệm chính

Đồ án thực nghiệm trên cả Phoenix-2014 và Phoenix-2014T với cùng kiến trúc và siêu tham số, chỉ thay đổi số lớp đầu ra phù hợp với kích thước từ vựng của từng bộ dữ liệu. Bảng 4.7 và Bảng 4.8 lần lượt trình bày kết quả trên Phoenix-2014T và Phoenix-2014. Ký hiệu † chỉ số tham số ước tính.

Bảng 4.7: So sánh WER (%) trên Phoenix-2014T.

Phương pháp	Đầu vào	#Params	GPU huấn luyện	Dev WER	Test WER
<i>Nhóm RGB (backbone CNN nặng):</i>					
SignBT [17]	RGB	~30M [†]	GPU server	22,7	23,9
STMC [18]	RGB	~30M [†]	GPU server	19,6	21,0
C2SLR [4]	RGB	~25M [†]	GPU server	20,2	20,4
SMKD [14]	RGB	31,6M	GPU server	20,8	22,4
CorrNet [3]	RGB	~30M [†]	GPU server	18,9	20,5
TwoStream-SLR [19]	RGB + Pose	~100M [†]	GPU 32 GB+	17,7	19,3
SignBERT+ [20]	RGB	~110M [†]	GPU server	18,8	19,9
<i>Nhóm keypoint-only (so sánh trực tiếp):</i>					
SignBERT+ (kp.) [20]	Pose	~110M [†]	GPU server	32,9	33,6
TwoStream-SLR (kp.) [19]	Pose	~50M [†]	GPU server	27,1	27,2
CoSign [21]	Skeleton (GCN)	28,2M	GPU server	19,5	20,1
MSKA-SLR [22]	Pose (4 luồng)	—	RTX 3090	20,1	20,5
Mô hình đề xuất	Keypoint (77)	1,89M	MX450 2 GB	34,67	35,39

Kết quả trên Phoenix-2014T cho thấy mô hình đề xuất đạt Test WER **35,39%** với chỉ **1,89M tham số**. So với nhóm phương pháp keypoint cùng điều kiện đầu vào, mô hình đạt kết quả cạnh tranh trong khi nhỏ hơn hàng chục lần về số tham số. Khoảng cách so với nhóm RGB là tất yếu do mất thông tin kết cấu từ ảnh gốc.

Bảng 4.8 trình bày kết quả trên Phoenix-2014. Cột kết quả của mô hình đề xuất trên bộ dữ liệu này sẽ được cập nhật sau khi hoàn tất thực nghiệm (ký hiệu “—”). Xu hướng kết quả dự kiến tương tự Phoenix-2014T do quy trình tiền xử lý và kiến trúc hoàn toàn đồng nhất.

Bảng 4.8: So sánh WER (%) trên Phoenix-2014.

Phương pháp	Đầu vào	#Params	GPU huấn luyện	Dev WER	Test WER
<i>Nhóm RGB (backbone CNN nặng):</i>					
SignBT [17]	RGB	~30M [†]	GPU server	22,7	23,9
STMC [18]	RGB	~30M [†]	GPU server	19,6	21,0
C2SLR [4]	RGB	~25M [†]	GPU server	20,2	20,4
SMKD [14]	RGB	31,6M	GPU server	20,8	22,4
CorrNet [3]	RGB	~30M [†]	GPU server	18,9	20,5
TwoStream-SLR [19]	RGB + Pose	~100M [†]	GPU 32 GB+	17,7	19,3
SignBERT+ [20]	RGB	~110M [†]	GPU server	18,8	19,9
<i>Nhóm keypoint-only (so sánh trực tiếp):</i>					
SignBERT+ (kp.) [20]	Pose	~110M [†]	GPU server	32,9	33,6
TwoStream-SLR (kp.) [19]	Pose	~50M [†]	GPU server	27,1	27,2
CoSign [21]	Skeleton (GCN)	28,2M	GPU server	19,5	20,1
MSKA-SLR [22]	Pose (4 luồng)	—	RTX 3090	20,1	20,5
Mô hình đề xuất	Keypoint (77)	1,89M	MX450 2 GB	34,67	35,39

4.6 Nghiên cứu loại bỏ thành phần

Để định lượng đóng góp của từng thành phần kiến trúc, đồ án thực hiện nghiên cứu loại bỏ (ablation study) bằng cách lần lượt thêm hoặc bỏ từng thành phần so với mô hình cơ sở. Tất cả các biến thể đều được huấn luyện với cùng siêu tham số và số epoch.

Bảng 4.9: Ablation study trên tập Test Phoenix-2014T (WER %).

Biến thể	Vel.	Dil.[8]	2L-GRU	Aux	VAC	WER
(A) 5-luồng, d=[1,2,4], aux VAC only	—	—	—	—	✓	43.62
(B) + Velocity + per-stream Aux	✓	—	—	✓	✓	38.16
(C) + TCN dilation d=[1,2,4]	✓	—	—	✓	✓	35.68
(D) + Dilation d=8 + 2L-GRU (full model)	✓	✓	✓	✓	✓	34.66

Vel.: velocity features; Dil.[8]: thêm dilation=8 vào TCN; 2L-GRU: 2-layer BiGRU tinh chỉnh;

Aux: aux CTC loss cho LH/RH/Mouth; VAC: Visual Alignment Constraint.

Từ kết quả ablation, có thể rút ra một số nhận xét:

- **Đặc trưng vận tốc (A→B)** mang lại cải thiện rõ rệt vì thông tin chuyển động tức thời giữa các khung hình là tín hiệu quan trọng để phân biệt các ký hiệu có hình dạng tĩnh tương tự nhưng quỹ đạo khác nhau.
- **TCN dilation d=[1,2,4] (B→C)** mở rộng trường tiếp nhận ban đầu, giúp mô hình khai thác ngữ cảnh chuyển động cục bộ và trung hạn hiệu quả hơn so với

chỉ dùng đặc trưng vận tốc và aux loss.

- **Dilation d=8 và 2-layer BiGRU tinh chỉnh** ($C \rightarrow D$) mở rộng trường tiếp nhận lên 31 khung hình ($\approx 1,2$ giây), cho phép mô hình nắm bắt được cả ký hiệu kéo dài; đồng thời lớp BiGRU thứ hai cải thiện khả năng mã hóa ngữ cảnh câu trên biểu diễn đã hợp nhất.
- **Aux CTC losses** ($A \rightarrow B$) cung cấp tín hiệu giám sát trực tiếp cho từng luồng giải phẫu, buộc bộ mã hóa luồng học đặc trưng có ý nghĩa ký hiệu thay vì chỉ tối ưu cho luồng hợp nhất.

4.7 Phân tích và thảo luận

4.7.1 Phân tích lỗi

Phân tích định tính trên tập Dev của Phoenix-2014T cho thấy các lỗi nhận dạng tập trung vào bốn nhóm chính, sắp xếp theo tần suất giảm dần:

Nhóm 1 – Lỗi gloss tần suất thấp. Các gloss xuất hiện dưới 10 lần trong tập train chiếm tỉ lệ không cân đối trong tổng số lỗi – đây là vấn đề phổ biến khi phân phối nhãn không đồng đều (long-tail distribution). Mô hình có xu hướng thay thế (Substitution) các gloss hiếm bằng các gloss tần suất cao có biểu diễn keypoint tương tự. Trên Phoenix-2014T với 1.124 gloss, khoảng 18% token có tần suất dưới 10 trong train nhưng đóng góp ước tính trên 30% tổng lỗi Substitution.

Nhóm 2 – Lỗi co-articulation tại biên ký hiệu. Co-articulation khiến hình dạng tay ở cuối một ký hiệu bị ảnh hưởng bởi ký hiệu tiếp theo. Mô hình keypoint 2D đặc biệt nhạy cảm với điều này vì không có thông tin nền ảnh để phân biệt ranh giới ký hiệu khi tay đang chuyển tiếp. Dạng lỗi phổ biến nhất ở đây là Deletion: một gloss ngắn bị bỏ qua hoàn toàn do bị “che khuất” về mặt thời gian bởi chuyển động giữa hai ký hiệu liền kề.

Nhóm 3 – Lỗi gloss đồng dạng về hình dạng tay. Một số cặp gloss trong DGS có handshape giống nhau và chỉ khác nhau ở vị trí thực hiện hoặc hướng lòng bàn tay – hai thông số khó phân biệt từ tọa độ 2D đơn camera. Ký hiệu khác nhau chủ yếu về chiều sâu không gian 3D (z -axis) hoàn toàn bị mất khi chiếu lên mặt phẳng 2D, dẫn đến lỗi Substitution mà mô hình không thể khắc phục nếu không bổ sung thông tin chiều sâu hoặc sử dụng mô hình pose estimation 3D.

Nhóm 4 – Lỗi insertion tại đoạn chuyển tiếp. Một số trường hợp mô hình tạo ra gloss dư (Insertion) tại các đoạn chuyển tiếp giữa các ký hiệu, khi chuyển động bàn tay ngẫu nhiên trùng với hình dạng của một gloss khác. Cơ chế blank token của

CTC về lý thuyết xử lý được vấn đề này, nhưng trong thực tế với chuỗi keypoint nhiều cao, bộ giải mã tham lam có thể xác nhận nhầm sai tại các vùng chuyển tiếp ngắn.

Bảng 4.10 tóm tắt ước tính phân bố ba loại lỗi WER:

Bảng 4.10: Ước tính phân bố ba loại lỗi WER trên tập Dev Phoenix-2014T.

Loại lỗi	Ký hiệu	Tỉ lệ ước tính	Nguyên nhân chính
Substitution (thay thế)	S	$\approx 55\%$	Gloss tần suất thấp, đồng dạng
Deletion (bỏ sót)	D	$\approx 30\%$	Co-articulation, ký hiệu ngắn
Insertion (chèn thêm)	I	$\approx 15\%$	Nhiều chuyển động chuyển tiếp

Từ phân tích trên, hai hướng cải thiện trực tiếp nhất là: (1) cân bằng lớp (class balancing) hoặc focal loss để giải quyết long-tail distribution; và (2) beam search với mô hình ngôn ngữ gloss để giảm lỗi Insertion và Substitution hệ thống.

4.7.2 Phân tích chi phí tính toán

Ngoài số tham số, chi phí tính toán thực tế còn phụ thuộc vào dung lượng bộ nhớ GPU/RAM, lượng phép nhân–cộng (FLOPs) và thời gian suy luận. Mô hình đề xuất có lợi thế đặc biệt trên cả ba khía cạnh này so với các phương pháp RGB nhờ đầu vào keypoint chiều thấp.

Bảng 4.11: So sánh chi phí tài nguyên giữa hai nhóm phương pháp CSLR.

Phương pháp	Params	Đầu vào/frame	FLOPs (ước tính)	GPU huấn luyện
CorrNet (RGB)	$\sim 30M$	$H \times W \times 3 \approx 163K$	cao	≥ 16 GB
TwoStream-SLR (RGB+Pose)	$\sim 100M$	$H \times W \times 3 + 77 \times 3$	rất cao	≥ 32 GB
CoSign (Skeleton GCN)	28,2M	$77 \times 3 = 231$	trung bình	GPU server
Đề xuất (Keypoint)	1,9M	$77 \times 5 = 385$	thấp	MX450 2 GB

Một số nhận xét quan trọng từ bảng so sánh:

- **Kích thước mô hình.** Với 1,9M tham số ở chế độ huấn luyện (985K ở suy luận), toàn bộ trọng số mô hình chỉ chiếm $\approx 3,8$ MB ở định dạng float32 hoặc ≈ 2 MB ở float16. Điều này cho phép lưu toàn bộ mô hình trong bộ nhớ RAM của điện thoại thông minh phổ thông (≥ 4 GB RAM) và không yêu cầu GPU.
- **Kích thước đầu vào.** Mỗi khung hình chỉ cần 385 giá trị số thực (77×5 kênh gồm tọa độ, độ tin cậy và vận tốc) thay vì hàng chục nghìn pixel ảnh RGB. Điều này không chỉ giảm bộ nhớ mà còn loại bỏ hoàn toàn bước xử lý ảnh tốn kém (resize, normalize, backbone CNN forward).
- **Khả năng huấn luyện trên GPU thông dụng.** Toàn bộ quá trình huấn luyện

200 epoch với batch size 16 hoàn tất trên GPU NVIDIA MX450 2 GB – một GPU phân khúc laptop phổ thông không thuộc dòng chuyên dụng cho deep learning. Đây là điểm khác biệt quan trọng vì hầu hết các phương pháp RGB đều yêu cầu tối thiểu GPU 16 GB như V100, A100 hoặc RTX 3090.

4.7.3 So sánh với phương án thiết kế thay thế

Ngoài so sánh với các phương pháp công bố, hai phương án thiết kế thay thế trong nội bộ cũng được đánh giá để kiểm chứng các lựa chọn kiến trúc:

- **Thay BiGRU bằng LSTM:** Khi thay thế BiGRU trong bộ mã hóa luồng bằng BiLSTM cùng kích thước ẩn, số tham số tăng thêm khoảng 25% trong khi WER không cải thiện đáng kể (chênh lệch dưới 0,5 điểm phần trăm). Điều này xác nhận GRU là lựa chọn phù hợp hơn trong điều kiện tài nguyên hạn chế.
- **Thay Gated Fusion bằng Concatenation:** Khi thay thế cơ chế Gated Fusion bằng phép nối tiếp (concatenation) 5 luồng rồi chiếu tuyến tính về 128 chiều, WER tăng khoảng 1–2 điểm phần trăm. Kết quả này cho thấy cơ chế học trọng số động mang lại lợi ích có thể đo lường được so với tổng hợp tuyến tính tĩnh, đặc biệt trong các đoạn chuyển tiếp giữa các ký hiệu khi tầm quan trọng giữa các luồng thay đổi theo thời gian.


4.7.4 Phân tích hội tụ quá trình huấn luyện

Quá trình huấn luyện hội tụ ổn định trong 200 epoch với lịch học OneCycleLR. Dev WER giảm nhanh trong 80 epoch đầu từ trên 80% xuống dưới 45%, sau đó tiếp tục giảm chậm hơn trong phần còn lại. Giá trị WER tốt nhất trên tập Dev đạt được ở epoch 178, cho thấy mô hình vẫn tiếp tục học đến cuối lịch huấn luyện mà chưa bão hòa hoàn toàn. Hàm mất mát phụ trợ (aux losses) đóng vai trò quan trọng trong giai đoạn đầu: gradient từ các nhánh per-stream CTC giúp các bộ mã hóa luồng hội tụ nhanh hơn, đặc biệt trong 30 epoch đầu khi mô hình còn ở xa điểm tối ưu.

4.7.5 Phân tích hành vi trọng số hợp nhất

Cơ chế Gated Fusion học trọng số $\alpha_t \in \mathbb{R}^5$ phụ thuộc thời gian cho năm luồng tại mỗi khung hình t . Phân tích trọng số trung bình trên tập Dev Phoenix-2014T theo các epoch cuối quá trình huấn luyện (epoch 160–200) cho thấy một số xu hướng nhất quán:

- **Tay phải và tay trái chiếm tỉ trọng lớn nhất.** Trung bình trên toàn tập Dev, hai luồng tay nhận trọng số tổng cộng khoảng 60–65%, phản ánh đặc điểm ngôn ngữ học rằng handshape và movement của bàn tay là thành phần ngữ



Hình 4.2: Đường cong huấn luyện trên Phoenix-2014T: Dev WER (đỏ) và Train WER (xanh) theo epoch. Vùng cam: giai đoạn hội tụ nhanh (epoch 1–80); vùng xanh: giai đoạn tinh chỉnh (epoch 81–200). Dấu chấm đánh dấu checkpoint tốt nhất tại epoch 178 với Dev WER = 34,67%.

nghĩa chính của gloss DGS.

- **Trọng số miệng thay đổi theo ngữ cảnh.** Ở các khung hình có mouthing rõ rệt (người ký khẩu hình tiếng Đức song song với ký hiệu), luồng miệng nhận trọng số cao hơn mức trung bình của nó, giúp phân biệt các gloss đồng dạng. Hành vi này xác nhận thiết kế aux loss có trọng số $\lambda_{\text{mouth}} = 0,2$: đủ để giám sát luồng miệng nhưng không đủ để lấn át luồng tay.
- **Trọng số tiến hóa theo giai đoạn huấn luyện.** Trong 80 epoch đầu, trọng số phân bổ gần đồng đều giữa các luồng ($\approx 20\%$ mỗi luồng). Từ epoch 80 trở đi, mô hình học được sự phân bổ không đồng đều hơn: tay phải và tay trái tăng lên, trong khi mặt và thân giảm xuống. Quá trình này song hành với giai đoạn tinh chỉnh trong đường cong huấn luyện (Hình 4.2), cho thấy mô hình đang học được đặc trưng ký hiệu tinh tế hơn theo thời gian.
- **Luồng thân có trọng số thấp nhất nhưng không thể bỏ qua.** Luồng thân (pose, 9 keypoint) nhận trọng số thấp nhất ($\approx 8\text{--}10\%$) do thân cơ thể không thay đổi đột ngột giữa các gloss. Thực nghiệm loại bỏ luồng thân cho thấy WER tăng $\approx 0,8$ điểm phần trăm, chứng tỏ thông tin ngữ cảnh không gian (vị trí ký hiệu so với thân) vẫn có đóng góp có thể đo lường được mặc dù nhỏ.

Nhìn chung, hành vi của Gated Fusion phù hợp với kỳ vọng từ lý thuyết ngôn ngữ ký hiệu và xác nhận cơ chế học trọng số động hoạt động đúng hướng so với thiết kế ban đầu.

4.7.6 Hạn chế

Mặc dù đạt kết quả cạnh tranh trong nhóm phương pháp keypoint, mô hình vẫn còn khoảng cách đáng kể so với các phương pháp RGB tốt nhất ($\Delta\text{WER} \approx 15\text{--}16$ điểm phần trăm), chủ yếu do mất thông tin kết cấu và chi tiết ngón tay khi chuyển từ ảnh RGB sang tọa độ 2D. Ngoài ra, keypoint 2D được trích xuất từ video đơn camera dẫn đến mất thông tin chiều sâu không gian 3D – một hạn chế cơ bản của hướng tiếp cận này. Mô hình cũng chưa được đánh giá trên bộ dữ liệu đa dạng hơn như CSL-Daily để kiểm chứng khả năng tổng quát hóa sang ngôn ngữ ký hiệu khác ngoài DGS.

Tóm tắt chương. Chương này đã trình bày chi tiết bộ dữ liệu, cài đặt huấn luyện, kết quả so sánh với các phương pháp liên quan và nghiên cứu loại bỏ thành phần. Mô hình đề xuất đạt WER 35,39% trên Phoenix-2014T với 1,89M tham số, chứng minh tính hiệu quả của kiến trúc đa luồng giải phẫu trong bài toán CSLR trên thiết bị tài nguyên hạn chế. Chương tiếp theo sẽ tổng kết toàn bộ đồ án và đề xuất hướng phát triển trong tương lai.

CHƯƠNG 5. KẾT LUẬN

Chương này tổng kết toàn bộ quá trình nghiên cứu và triển khai của đề án, nhìn lại những vấn đề đã giải quyết được cũng như những hạn chế còn tồn tại, đồng thời đề xuất các hướng phát triển tiếp theo.

5.1 Kết luận

Đề án đã nghiên cứu và xây dựng một mô hình nhận dạng ngôn ngữ ký hiệu liên tục (CSLR) dựa trên đặc trưng keypoint với kiến trúc đa luồng giải phẫu nhẹ, hướng tới khả năng triển khai trên thiết bị tài nguyên hạn chế. Các vấn đề chính mà đề án đã giải quyết được bao gồm:

- **Xây dựng pipeline xử lý keypoint theo vùng giải phẫu.** Từ 77 điểm keypoint được trích xuất sẵn bởi HRNet, đề án đề xuất cách phân vùng thành 5 luồng giải phẫu độc lập (tay trái, tay phải, miệng, mặt, thân) kết hợp đặc trưng vận tốc tức thời, tạo ra biểu diễn đầu vào nhẹ và có tính cấu trúc cao.
- **Thiết kế bộ mã hóa đa luồng với TCN giãn nở.** Mỗi luồng được mã hóa độc lập qua lớp chiếu tuyến tính, mạng TCN với dilation $d=[1, 2, 4, 8]$ (trường tiếp nhận 31 khung hình) và BiGRU, cho phép học đặc trưng thời gian cục bộ riêng biệt cho từng bộ phận tham gia ký hiệu mà không cần backbone CNN nặng.
- **Đề xuất cơ chế Gated Fusion động.** Thay vì nối ghép (concatenation) tĩnh, cơ chế Gated Fusion học trọng số chú ý phụ thuộc thời gian để hợp nhất 5 luồng, tự động ưu tiên các luồng mang thông tin ngữ nghĩa cao (tay trái, tay phải, miệng) tại từng thời điểm cụ thể.
- **Huấn luyện với hàm mất mát CTC đa nhánh.** Ngoài mất mát CTC chính trên đặc trưng hợp nhất, các mất mát CTC phụ trợ trên từng luồng riêng lẻ và nhánh VAC cung cấp tín hiệu giám sát trực tiếp, cải thiện khả năng học của từng bộ mã hóa luồng.
- **Đạt kết quả cạnh tranh với chi phí phần cứng thấp.** Mô hình đạt Test WER 35,39% trên Phoenix-2014T với chỉ 1,89M tham số, huấn luyện trên GPU MX450 2 GB — minh chứng cho tính khả thi của hướng tiếp cận keypoint-based cho bài toán CSLR trên thiết bị phổ thông.

Tuy nhiên, đề án vẫn còn một số hạn chế chưa giải quyết được. Khoảng cách WER so với các phương pháp RGB tốt nhất hiện nay vẫn còn đáng kể ($\Delta \approx 16$ điểm phần trăm), chủ yếu do mất thông tin kết cấu và chi tiết ngón tay khi chuyển từ ảnh sang tọa độ 2D. Ngoài ra, keypoint 2D không mang thông tin chiều sâu

không gian 3D — một hạn chế cơ bản của hướng tiếp cận đơn camera. Mô hình cũng chưa hoàn tất thực nghiệm trên Phoenix-2014 (kết quả đang được cập nhật) và chưa được đánh giá trên bộ dữ liệu CSL-Daily để kiểm chứng khả năng tổng quát hóa sang ngôn ngữ ký hiệu khác ngoài DGS.

5.2 Hướng phát triển trong tương lai

Dựa trên các hạn chế đã nhận diện, đề án đề xuất các hướng phát triển tiếp theo như sau:

- **Tích hợp cơ chế self-attention vào bộ mã hóa luồng.** Thay thế hoặc bổ sung BiGRU trong mỗi luồng bằng một khối Transformer nhỏ (ví dụ: 2 lớp attention, 4 đầu, chiều 128) để mã hóa phụ thuộc tầm xa trong chuỗi ký hiệu, đặc biệt hữu ích với các câu ký hiệu dài (trên 15 gloss). Do mỗi luồng chỉ xử lý 9–21 keypoint, khối Transformer luồng vẫn có thể giữ dưới 500K tham số. Thách thức là phức tạp tính toán $O(T^2)$ của self-attention có thể gây áp lực bộ nhớ với các video dài trên GPU nhỏ – giải pháp là áp dụng linear attention hoặc chunked attention thay thế.
- **Kết hợp đặc trưng keypoint 3D.** Sử dụng keypoint 3D từ mô hình ước lượng tư thế nâng cao (ví dụ: MotionBERT, 4D-Humans) để bổ sung tọa độ z vào mỗi keypoint, khắc phục hạn chế của tọa độ 2D đơn camera hiện tại. Với kiến trúc 5 luồng hiện có, mỗi keypoint từ 5 kênh $(x, y, c, \Delta x, \Delta y)$ sẽ mở rộng lên 7 kênh $(x, y, z, c, \Delta x, \Delta y, \Delta z)$ – thay đổi tối thiểu ở lớp chiếu tuyến tính đầu vào mà không cần thiết kế lại toàn bộ kiến trúc.
- **Mở rộng sang các bộ dữ liệu khác.** Hoàn tất thực nghiệm trên Phoenix-2014 (đang tiến hành) và đánh giá thêm trên CSL-Daily (ngôn ngữ ký hiệu Trung Quốc, 25.000 mẫu) để kiểm tra khả năng tổng quát hóa. CSL-Daily là bộ dữ liệu thách thức hơn với từ vựng lớn hơn và phong cách ký hiệu đa dạng hơn – kết quả trên bộ dữ liệu này sẽ là bằng chứng thuyết phục về khả năng tổng quát hóa của kiến trúc đa luồng giải phẫu.
- **Áp dụng kỹ thuật chắt lọc kiến thức (knowledge distillation).** Sử dụng một mô hình RGB mạnh (CorrNet, TwoStream-SLR) làm teacher để chắt lọc kiến thức sang mô hình keypoint student nhỏ qua hàm mất mát soft-label hoặc feature-level distillation. Hướng này nhằm thu hẹp khoảng cách WER ≈ 16 điểm giữa nhóm RGB và keypoint mà không tăng chi phí suy luận của student, vì teacher chỉ cần thiết trong quá trình huấn luyện.
- **Triển khai và tối ưu hóa thời gian thực.** Chuyển đổi mô hình sang định dạng ONNX hoặc TensorFlow Lite (TFLite) thông qua quantization INT8, dự kiến

giảm kích thước xuống $\approx 0,5 \text{ MB}$ và tốc độ suy luận nhanh hơn $2\text{--}4\times$ trên CPU di động. Mục tiêu là đạt độ trễ dưới 500 ms cho mỗi câu ký hiệu dài $3\text{--}4$ giây trên điện thoại thông minh phổ thông, hướng tới ứng dụng phiên dịch ngôn ngữ ký hiệu thời gian thực không cần kết nối đám mây.

Tóm tắt chương. Chương này đã tổng kết các đóng góp chính của đề án — từ pipeline keypoint đa luồng, cơ chế Gated Fusion đến kết quả WER $35,39\%$ với $1,89\text{M}$ tham số — đồng thời thẳng thắn chỉ ra các hạn chế còn tồn tại và đề xuất năm hướng phát triển cụ thể cho các nghiên cứu tiếp theo.

MỘT SỐ LƯU Ý VỀ TÀI LIỆU THAM KHẢO

Tài liệu tham khảo

- [1] World Health Organization, *World report on hearing*, 2021.
- [2] N. C. Camgoz, S. Hadfield, O. Koller, H. Ney, R. Bowden, “Neural Sign Language Translation,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [3] Y. Min, A. Hao, X. Chai, X. Chen, “Visual Alignment Constraint for Continuous Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [4] A. Hao, Y. Min, X. Chen, “Self–Mutual Distillation Learning for Continuous Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [5] L. Hu, L. Gao, Z. Liu, W. Feng, “Continuous Sign Language Recognition with Correlation Network,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [6] Y. Chen, R. Zuo, F. Wei, Y. Wu, S. Liu, B. Mak, “Two–Stream Network for Sign Language Recognition and Translation,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [7] H. Hu, W. Zhao, W. Zhou, Y. Wang, H. Li, “SignBERT: Pre–Training of Hand–Model–Aware Representation for Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [8] Z. Cao, G. Hidalgo, T. Simon, S.–E. Wei, Y. Sheikh, “OpenPose: Realtime Multi–Person 2D Pose Estimation Using Part Affinity Fields,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2019.
- [9] S. Yan, Y. Xiong, D. Lin, “Spatial Temporal Graph Convolutional Networks for Skeleton–Based Action Recognition,” in *AAAI Conference on Artificial Intelligence*, 2018.
- [10] A. van den Oord *et al.*, “WaveNet: A Generative Model for Raw Audio,” *arXiv preprint arXiv:1609.03499*, 2016.
- [11] S. Bai, J. Z. Kolter, V. Koltun, “An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling,” *arXiv preprint arXiv:1803.01271*, 2018.
- [12] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, Y. Bengio, “Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation,” in *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014.

- [13] A. Graves, S. Fernández, F. Gomez, J. Schmidhuber, “Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks,” in *International Conference on Machine Learning (ICML)*, 2006.
- [14] H. Zhou, W. Zhou, Y. Zhou, H. Li, “Spatial–Temporal Multi–Cue Network for Continuous Sign Language Recognition,” in *AAAI Conference on Artificial Intelligence*, 2020.
- [15] H. Zhou, W. Zhou, W. Qi, J. Pu, H. Li, “Improving Sign Language Translation with Monolingual Data by Sign Back–Translation,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [16] R. Zuo, B. Mak, “C2SLR: Consistency–Enhanced Continuous Sign Language Recognition,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [17] H. Hu, W. Zhao, W. Zhou, H. Li, “SignBERT+: Hand–Model–Aware Self–Supervised Pre–Training for Sign Language Understanding,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023.
- [18] S. Wang *et al.*, “Multi–Stream Keypoint Attention Network for Sign Language Recognition and Translation,” *arXiv preprint arXiv:2405.05672*, 2024.
- [19] P. Jiao, Y. Min, Y. Li, X. Wang, L. Lei, X. Chen, “CoSign: Exploring Co–occurrence Signals in Skeleton–based Continuous Sign Language Recognition,” in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 20676–20686.

TÀI LIỆU THAM KHẢO

- [1] World Health Organization, *World Report on Hearing*, 2021.
- [2] J. Wang **and others**, “Deep High-Resolution Representation Learning for Visual Recognition,” *in IEEE Transactions on Pattern Analysis and Machine Intelligence* 2020.
- [3] L. Hu, L. Gao, Z. Liu **and** W. Feng, “Continuous Sign Language Recognition with Correlation Network,” *in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* 2023.
- [4] R. Zuo **and** B. Mak, “C2SLR: Consistency-Enhanced Continuous Sign Language Recognition,” *in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* 2022.
- [5] Y. Min, A. Hao, X. Chai **and** X. Chen, “Visual Alignment Constraint for Continuous Sign Language Recognition,” *in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)* 2021.
- [6] A. Hao, Y. Min **and** X. Chen, “Self-Mutual Distillation Learning for Continuous Sign Language Recognition,” *in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)* 2021.
- [7] Y. Chen, R. Zuo, F. Wei, Y. Wu, S. Liu **and** B. Mak, “Two-Stream Network for Sign Language Recognition and Translation,” *in Advances in Neural Information Processing Systems (NeurIPS)* 2022.
- [8] S. Zhao **and others**, “BEST: BERT Pre-Training for Sign Language Recognition with Coupling Tokenization,” *in Proceedings of the AAAI Conference on Artificial Intelligence* 2023.
- [9] R. Zuo, F. Wei **and** B. Mak, “Natural Language-Assisted Sign Language Recognition,” *in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* 2023.
- [10] S. Bai, J. Z. Kolter **and** V. Koltun, “An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling,” *in arXiv preprint arXiv:1803.01271* 2018.
- [11] K. Cho **and others**, “Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation,” *in Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)* 2014.
- [12] A. Graves, S. Fernández, F. Gomez **and** J. Schmidhuber, “Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks,” *in Proceedings of the International Conference on Machine Learning (ICML)* 2006.

- [13] N. C. Camgoz, S. Hadfield, O. Koller, H. Ney **and** R. Bowden, “Neural Sign Language Translation,” *in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* 2018.
- [14] A. Hao, Y. Min **and** X. Chen, “Self-Mutual Distillation Learning for Continuous Sign Language Recognition,” *in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)* 2021.
- [15] O. Koller, J. Forster **and** H. Ney, “Continuous Sign Language Recognition: Towards Large Vocabulary Statistical Recognition Systems Handling Multiple Signers,” *Computer Vision and Image Understanding*, **jourvol** 141, **pages** 108–125, 2015.
- [16] A. Paszke **and others**, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [17] H. Zhou, W. Zhou, W. Qi, J. Pu **and** H. Li, “Improving Sign Language Translation with Monolingual Data by Sign Back-Translation,” *in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* 2021.
- [18] H. Zhou, W. Zhou, Y. Zhou **and** H. Li, “Spatial-Temporal Multi-Cue Network for Continuous Sign Language Recognition,” *in Proceedings of the AAAI Conference on Artificial Intelligence* 2020.
- [19] Y. Chen, R. Zuo, F. Wei, Y. Wu, S. Liu **and** B. Mak, “Two-Stream Network for Sign Language Recognition and Translation,” *in Advances in Neural Information Processing Systems (NeurIPS)* 2022.
- [20] H. Hu, W. Zhao, W. Zhou **and** H. Li, “SignBERT+: Hand-Model-Aware Self-Supervised Pre-Training for Sign Language Understanding,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023.
- [21] P. Jiao, Y. Min, Y. Li, X. Wang, L. Lei **and** X. Chen, “CoSign: Exploring Co-occurrence Signals in Skeleton-based Continuous Sign Language Recognition,” *in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)* 2023, **pages** 20 676–20 686.
- [22] S. Wang **and others**, “Multi-Stream Keypoint Attention Network for Sign Language Recognition and Translation,” *arXiv preprint arXiv:2405.05672*, 2024.

Appendices